机器学习

课程设计报告

四项 Kaggle 任务的建模与优化

姓名　高子恒

学号　20245613

班级　人工智能 2402

东北大学　计算机科学与工程学院

2026 年 11 月

摘要

本报告汇总课程设计中的四项任务，均以 Kaggle 竞赛形式给出：小样本植物图像分类、人脸表情识别、眼底黄斑中央凹定位与眼底血管分割。四者分别对应小样本分类、类别不均衡的细粒度分类、目标检测与坐标回归、医学图像二值分割四类典型问题。

四项任务共用一条技术主线：以 ImageNet 预训练骨干为基础做迁移学习，配合与任务匹配的数据增强，按验证集指标保存最佳轮次，最后用多折集成与测试时增强（TTA）压低方差。在此之上，各任务的处理重点不同：植物分类考察小样本下正则化与模型容量的取舍；表情识别考察输入分辨率与类别不均衡的处理；黄斑定位把坐标回归转化为“检测框中心”的检测问题；血管分割的关键在于损失函数对漏检的惩罚、阈值选取与提交格式。

主要结果（验证集指标＋线上提交成绩）：

· 植物图像分类：五折 Macro-F1，ResNet18 为 0.8998，EfficientNet-B0 为 0.9152；线上提交两次，0.9074 与 0.9047；

· 人脸表情识别：最佳验证准确率 0.6834（第 20 轮），线上 0.679；另一版本（15 轮、重采样、无 TTA）线上 0.678，两版只差 0.001；

· 黄斑中央凹定位：五折验证 RMSE 各折为 14.76、15.89、4.58、17.66、16.90，均值 13.96；线上私榜 17.42、终榜 21.11。另有一次独立训练在 fold4 崩溃（OOF 33.00），两相对照说明小数据下的不稳定性；

· 眼底血管分割：五折验证 Dice 均值 0.7863（第二次独立运行为 0.7812）；线上私榜 0.82632、终榜 0.82947。

报告中的全部数值均取自 notebook 的实际运行输出，未做修饰。四项任务也留下了若干值得记录的判断，例如植物分类中增强与正则整体是正贡献（移除绝大多数模块都掉分）、表情识别中输入分辨率的影响大于更换骨干网络、黄斑定位同一配置两次运行的五折均值可以从 13.96 px 变成 33.00 px，这些结论连同证据一并写在对应章节中。

关键词：迁移学习；小样本分类；类别不均衡；目标检测；医学图像分割；交叉验证集成

引言

四项任务一览

任务	类型	数据（训练/测试）	验证结果	线上成绩
植物分类	小样本	500 / 378	Macro-F1 0.9152（五折）	0.9074、0.9047
表情识别	细粒度	28275 / 7065	Accuracy 0.6834	0.679
黄斑定位	检测＋回归	80 / 20	RMSE 13.96（五折均值）	私 17.42 / 终 21.11
血管分割	语义分割	20 对 / 20	Dice 0.7863 / 0.7812	私 0.82632 / 终 0.82947

四项任务的测试集均不提供标签。各章报告的是该任务**最终提交、线上成绩最好**的那次运行；验证指标取自对应 notebook 的实际输出，线上成绩取自 Kaggle 排行榜，私榜与终榜分别列出。若同一配置另有独立运行且结果差异明显，一并列出，用于说明小数据下的方差。

共同的技术路线

四项任务的数据规模都不足以从零训练深度网络，因此统一采用迁移学习：

1. **骨干**：以 ImageNet 预训练的 ResNet18 为主，另在对照中尝试 EfficientNet-B0、ResNet34、ResNet50、Faster R-CNN（ResNet50-FPN）与 UNet（ResNet18 编码器）；
2. **输入**：分类任务统一放大到 224×224，分割任务 768×768，检测任务 800×800，均使用 ImageNet 均值方差归一化；
3. **增强**：分类任务用翻转、旋转、颜色扰动与随机擦除，检测与分割任务用图像和标注同步变换；

4. **训练**：AdamW 为主，余弦退火或阶段式学习率，按验证集指标保存最佳轮次，配合早停与梯度裁剪；
5. **推理**：多折模型集成，叠加翻转类 TTA，最后按竞赛模板重排提交文件。

报告组织

四个任务各自独立成章，依次为第 1 至第 4 章，每章结构一致：任务与数据、方法设计、实验设置、结果、分析、局限与改进。开头的引言说明四项任务的共同背景与技术路线，结语只做简短收束，不复述各章结论。附录给出复现信息与代码仓库地址。

第 1 章　小样本植物图像分类

1.1 任务与数据

本任务为 5 类植物幼苗图像的单标签分类，类别为 Black-grass、Common wheat、Loose Silky-bent、Scentless Mayweed 与 Sugar beet，评价指标为 Macro-F1。训练集 500 张，5 类各 100 张，完全均衡；测试集 378 张，不提供标签。图像统一缩放至 224×224，背景多为土壤，光照与拍摄距离差异明显。每类仅 100 张且禁用外部数据，模型容易依赖背景而非叶片形态；Black-grass 与 Loose Silky-bent 苗期均为细长窄叶，类间边界模糊，因此方法需以迁移学习为主。

1.2 方法设计

1.2.1 整体框架

训练图经随机增强送入 ImageNet 预训练骨干，再由 Dropout 与线性层输出 5 类 logits；两阶段训练后，集成 5 折×2 骨干共 10 个模型，推理时再做水平翻转 TTA。

1.2.2 模型结构与训练策略

ResNet18 参数量 11.18M，特征维度 512；EfficientNet-B0 参数量 4.01M，特征维度 1280。两者均加载 ImageNet 权重，分类头改为 Dropout(0.5)加 Linear(→5)。第

一阶段冻结骨干，仅训练分类头 8 轮，学习率 1e-3；第二阶段解冻全部参数，微调 30 轮，学习率 1e-4，采用 CosineAnnealing，patience=5。前者避免新初始化的分类头破坏预训练特征，后者使骨干适配植物域。优化器为 AdamW，batch size 为 16，weight_decay 为 1e-4，LabelSmoothing 为 0.1。

1.2.3 数据增强

表 1-1　训练阶段的数据增强

增强方式	参数	设计动机
RandomResizedCrop	scale=(0.7,1.0)	模拟尺度变化
RandomHorizontalFlip	p=0.5	利用左右对称性
RandomRotation	15°	覆盖拍摄角度变化
ColorJitter	亮度、对比度、饱和度均为 0.3	适应光照差异
RandomErasing	p=0.25	模拟局部遮挡

1.2.4 集成与 TTA

按 StratifiedKFold 划分 5 折，seed=42，每折训练两个骨干，共 10 个模型。推理时对原图与水平翻转图的 softmax 概率取平均，再对 10 个模型等权平均后取 argmax。概率平均比投票更平滑，可削弱单模型的过置信错误。

1.3 实验设置

表 1-2　训练与交叉验证设置

项目	设置
交叉验证	StratifiedKFold，5 折，seed=42
每折训练/验证	400 张/100 张
batch size	16
优化器	AdamW，weight_decay=1e-4
阶段一	冻结骨干，8 轮，lr=1e-3
阶段二	全参数，30 轮，lr=1e-4，CosineAnnealing，patience=5
集成	5 折×2 骨干=10 模型，水平翻转 TTA

消融固定 Fold 0 与 seed=42，共 13 项配置，每次只关闭或替换一个模块，baseline 为 0.9199。超参数搜索在第二个 notebook 中完成，覆盖微调学习率、Dropout 与 LabelSmoothing 三组，主配置取 lr=1e-4、Dropout=0.5、LabelSmoothing=0.1。每折在 100 张验证样本上计算 Macro-F1，报告 5 折均值、标准差及最好/最差折。测试集无标签，只能报告预测分布，不能计算 F1，也不能用于模型选择。

1.4 结果

1.4.1 两模型五折对比

表 1-3　ResNet18 与 EfficientNet-B0 的五折结果（Macro-F1）

模型	参数量	5 折均值	标准差	最好折	最差折
ResNet18	11.18M	0.8998	0.0316	0.9300	0.8455
EfficientNet-B0	4.01M	0.9152	0.0381	0.9599	0.8460

EfficientNet-B0 的均值高 0.0154，最好折高 0.0299；最差折 0.8460 与 0.8455 几乎相同。但它的标准差 0.0381 高于 0.0316，极差 0.1139 也大于 0.0845——上限更高，波动也更大。图 1-1 中 ResNet18 在第 10 轮前后进入平台期，EfficientNet-B0 到第 16 轮附近才见顶。

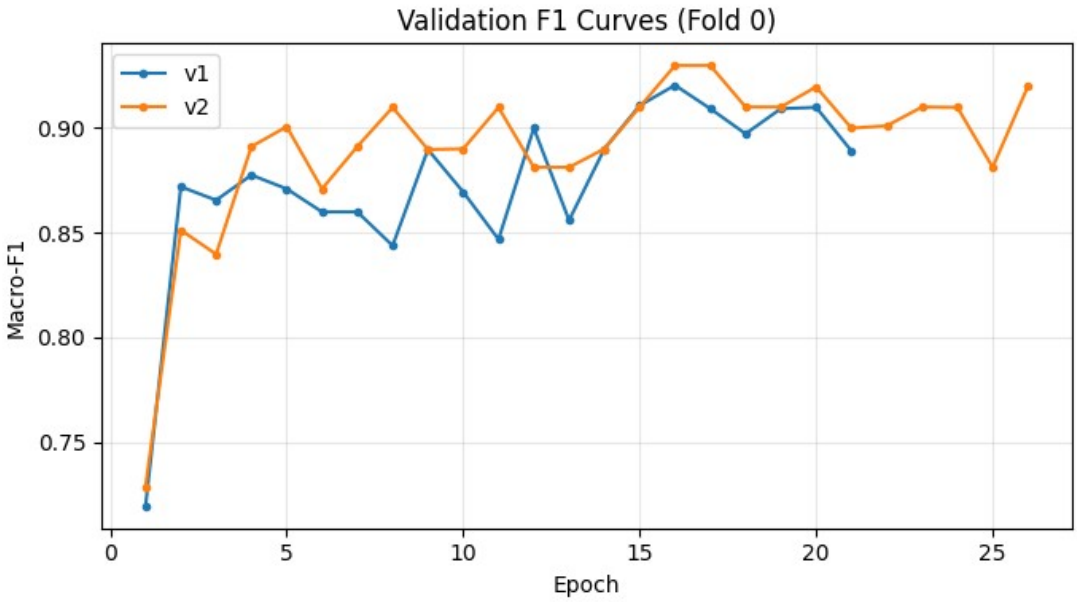


图 1-1　两模型在 Fold 0 上的验证 Macro-F1 曲线

图 1-2 为 ResNet18 在 Fold 0 的混淆矩阵，Macro-F1 为 0.9204，100 张验证图里 8 张错分。

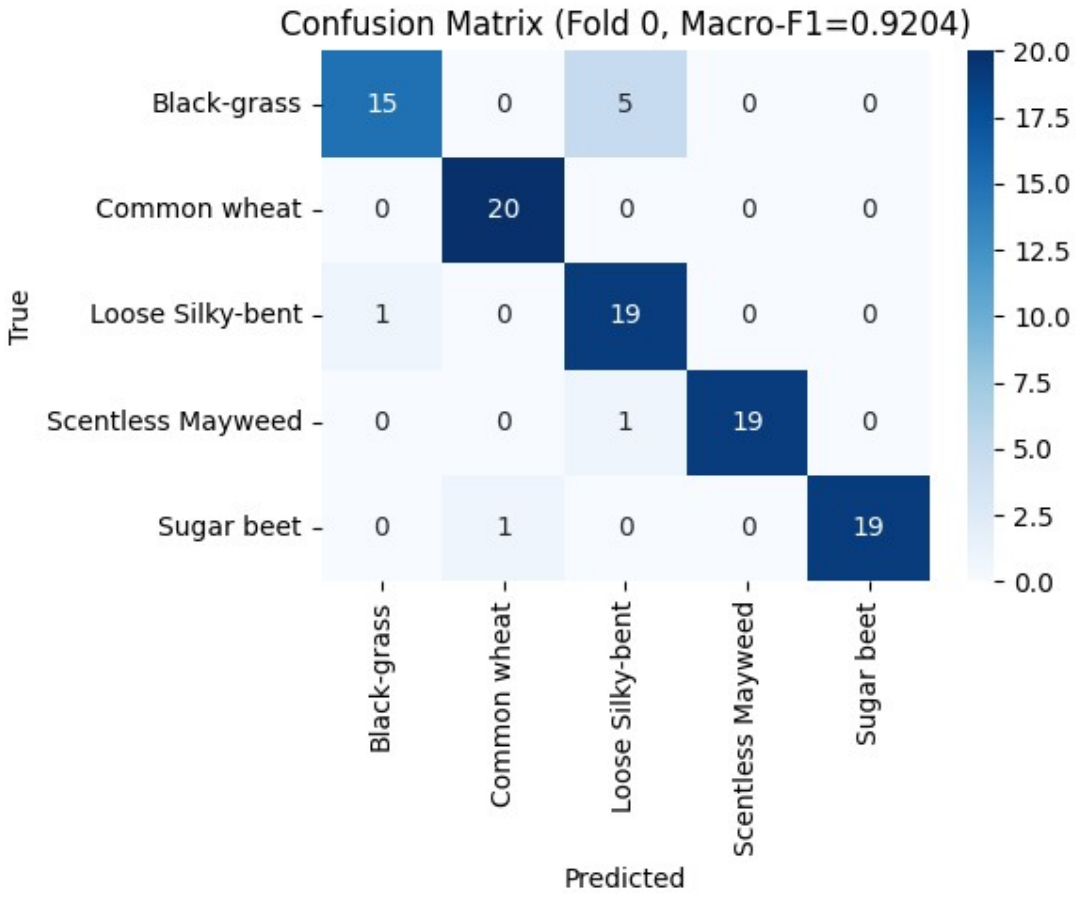


图 1-2　Fold 0 混淆矩阵（ResNet18）

1.4.2 集成与 TTA

10 个模型集成加水平翻转 TTA 后，测试集的预测分布见表 1-4。训练集五类完全均衡，各 100 张；预测分布却明显偏斜，Loose Silky-bent 104 张，Common wheat 只有 37 张，相差 67 张。测试集无标签，这个分布只能说明模型的预测倾向，不能据此计算 F1。

表 1-4　10 模型集成加 TTA 的测试集预测分布

类别	测试集预测数
Loose Silky-bent	104
Scentless Mayweed	91
Sugar beet	82
Black-grass	64
Common wheat	37

1.4.3 消融实验

消融固定 Fold 0，每次只移除或替换一个模块，baseline 为 0.9199，结果见表 1-5 与图 1-3。除 no_erasing 与 baseline 持平（+0.0008，在噪声内）外，其余 11 项全部低于 baseline。

表 1-5　消融实验结果（Fold 0，baseline 0.9199）

配置	Macro-F1	Δ vs baseline
no_erasing	0.9207	+0.0008
baseline	0.9199	0
no_freeze	0.9107	−0.0092
no_dropout	0.9098	−0.0101
efficientnet_b0	0.9098	−0.0101
no_crop	0.9009	−0.0190
no_cosine	0.8999	−0.0200
with_mixup	0.8999	−0.0200
no_label_smoothing	0.8999	−0.0200
no_flip	0.8970	−0.0229
no_colorjitter	0.8897	−0.0302
no_weight_decay	0.8897	−0.0302
no_rotation	0.8789	−0.0410

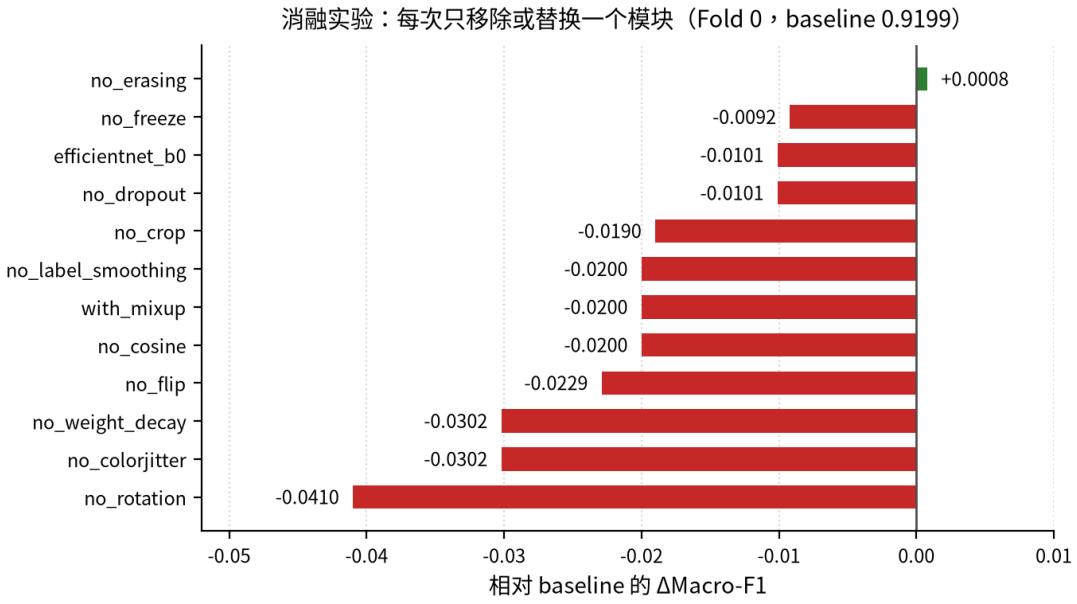


图 1-3　消融实验：各模块相对基线的 ΔMacro-F1

1.4.4 线上成绩

Kaggle 提交两次：第一次（task1）公开榜 0.9074，第二次（task1-2nd）0.9047。两次都低于验证集最优的 0.9152，差距在 0.01 上下，与五折标准差

（0.0316–0.0381）同量级。测试集 378 张，验证每折仅 100 张，两者分布不完全一致，因此线上低于验证属正常范围，不能据此断定过拟合。

1.5 分析

1.5.1 EfficientNet-B0 更优的原因

EfficientNet-B0 在五折均值上领先 0.0154。可能的原因有三：MBConv 的深度可分离卷积与 SE 注意力对细粒度纹理更敏感；4.01M 参数仅为 ResNet18 的 36%，在 500 张样本下容量更可控；复合缩放让深度、宽度与分辨率更平衡。但它的标准差 0.0381 高于 0.0316，均值差小于一个标准差，只能称其在本数据划分下平均更好，不能断言显著占优。

值得注意的是，单折消融里 efficientnet_b0 为 0.9098（−0.0101），与五折结论方向相反。查配置可知，两者不是同一个实验：消融只替换了 backbone，其余沿用 baseline 的 epochs_finetune=30、patience=5；而主流程的 EfficientNet-B0 用的是 40 轮、patience=10。同一折上，主流程的 EfficientNet-B0 为 0.9298，消融版本为 0.9098，0.0200 的差距完全来自训练轮数，与模型结构无关。

逐折看，主流程中 EfficientNet-B0 在五折上都不低于 ResNet18（Fold 0 +0.0094、Fold 1 +0.0299、Fold 2 +0.0005、Fold 3 +0.0272、Fold 4 +0.0096），方向一致。因此模型选择以五折完整评估为准；消融里的 efficientnet_b0 只用于“同折、同预算下换 backbone”的对照，不用于跨模型结论。

1.5.2 增强与正则整体有效

除 no_erasing 外，移除任何一个模块都使 Fold 0 的分数下降：影响最大的是旋转（no_rotation，−0.0410），其次是颜色扰动与权重衰减（各 −0.0302），再次是翻转（−0.0229）、余弦退火与标签平滑（各 −0.0200）。这与“小样本应当加强正则”的直觉一致：数据只有 500 张，增强扩大了有效样本量，正则抑制了过拟合。

有两处需要谨慎解读。其一，no_erasing 为 +0.0008，与 baseline 相差不到千分之一，属噪声；RandomErasing 遮挡 25% 的叶片区域，可能同时抹掉了判别性纹

理，作用方向不稳定。其二，消融只跑 Fold 0、每个配置一次，0.01 量级以下的差异不能当作定论。

1.5.3 小样本下的方差问题

两模型五折标准差为 0.0316 与 0.0381，极差为 0.0845 与 0.1139，对划分敏感。每折验证只有 100 张，单张样本的归属变化即可改变 Macro-F1 约 0.01。0.0154 的均值差小于标准差，不宜做显著性断言；线上两次提交相差 0.0027，也在这个量级内。10 个模型集成加 TTA 在预测层面平均多个输出，有助于降低方差，因此最终提交采用集成而非单折最优模型。

1.5.4 类间混淆集中在两种禾草

图 1-2 的 8 例错分中，6 例发生在 Black-grass 与 Loose Silky-bent 之间：5 例 Black-grass 被判成 Loose Silky-bent，1 例反向。两者苗期都是细长窄叶，缩放后纹理接近，叶宽与颜色差异被削弱。其余两例分别是 Scentless Mayweed 判成 Loose Silky-bent、Sugar beet 判成 Common wheat，各 1 例。

这一分布与测试集预测偏斜方向一致：Loose Silky-bent 被多判（104 张），Common wheat 被少判（37 张）。若测试集类别均衡，模型对 Common wheat 的召回会偏低。后续应针对这一对相似类引入度量学习或二阶段分类器，而不是继续整体加强正则。

1.6 局限与改进

局限有五：测试集无标签，线上与验证之间存在约 0.01 的差距，无法进一步归因；消融仅 Fold 0 且未重复，无置信区间；超参搜索只覆盖三个维度；两阶段轮数与 patience 固定，未与正则强度联合调优；集成加 TTA 的推理开销约为单模型 20 倍。

改进方向：采用 5×5 重复交叉验证，对关键配置使用 3 个随机种子重复；用嵌套交叉验证联合选择正则强度与早停轮数；按类报告 F1 与混淆矩阵，对 Loose Silky-bent 与 Black-grass 引入度量学习或二阶段分类器；在参数量受控下尝试更强预训练权重，并用类先验校正缓解分布偏移。

第 2 章　人脸表情识别

人脸表情识别是细粒度图像分类任务。本章介绍六类表情识别的数据、迁移学习方案与实验结果，并分析影响验证性能的主要因素。

2.1 任务与数据

2.1.1 任务定义

输入一张人脸图像，输出 Angry、Fear、Happy、Sad、Surprise、Neutral 六类之一，以 Accuracy 评价。测试集无公开标签，提交须按模板 ID 排序，故模型选择仅依据验证集。

2.1.2 数据与类别分布

训练集 28275 张，均为 48×48 灰度图（L 模式）；测试集 7065 张，与提交模板 ID 完全对应，缺失 0。类别分布见表 2-1，Happy 最多、Surprise 最少，最大/最小为 2.25，存在中度不平衡。

表 2-1　训练集类别分布

类别	样本数
Angry	3963
Fear	4097
Happy	7192
Sad	4862
Surprise	3202
Neutral	4959
合计	28275

2.2 方法设计

2.2.1 模型与预处理

以 ImageNet 预训练 ResNet18 为主干，最后一层全连接改为 6 类。ResNet18 由残差块构成，参数量适中，适合在有限数据上微调。图像由 L 模式转 RGB，缩放至 224×224 并按 ImageNet 均值、标准差归一化。训练增强为 RandomHorizontalFlip、RandomRotation(10)、ColorJitter(0.2,0.2)；验证和测试仅做确定性缩放与归一化。

2.2.2 划分与训练策略

按 85%/15%分层划分，seed=42，训练约 24034 张、验证约 4241 张；分层保持各类别比例，降低验证集构成偏斜。损失为 CrossEntropyLoss，优化器 AdamW，lr=1e-4、weight_decay=1e-4，CosineAnnealingLR 的 T_max=30。最多训练 30 轮，batch size=32，shuffle=True 且不重采样；以验证准确率监控，patience=5，保存最佳权重并于早停后回滚。

2.2.3 TTA

对原图和水平翻转图各前向一次，对两组 logits 取平均后 argmax；不是对 softmax 概率取平均。TTA 仅用于生成提交。

2.3 实验设置

主实验 N2 使用上述 30 轮配置。N1 作为训练策略参照：训练 15 轮、使用 WeightedRandomSampler、无 TTA。对照模型 EfficientNet-B0 采用相同数据划分与训练框架。消融共 7 组，每组 6 轮并固定同一划分，以 ResNet50、224×224、基础增强为基线，分别改变主干、输入尺寸、采样或正则；6 轮结果只作横向筛选。所有报告值均为验证集最佳 Accuracy，测试标签未参与调参。

2.4 实验结果

2.4.1 主模型

N2 最佳验证准确率 0.6834，出现在第 20 轮，第 25 轮早停；N1 最佳为 0.6763。N2 较 N1 高 0.71 个百分点，但 N1 仅训练 15 轮且使用重采样，差异不能视为单变量收益。N2 经 TTA 的提交预测为 Angry 759、Fear 820、Happy 1781、Sad 1375、Surprise 803、Neutral 1527，六类均有输出，合计 7065 条，未发生类别坍缩。

2.4.2 对照模型

EfficientNet-B0 最佳验证 0.6711，第 6 轮见顶、第 11 轮早停，比 ResNet18 低 1.23 个百分点，差距有限，尚不足以判定主干优劣。

2.4.3 消融实验

表 2-2 和图 2-1 给出 7 组结果。关闭重采样后，最佳验证准确率由 0.6721 升至 0.6846，提升 1.25 个百分点，为最大正向改动；换 ResNet18 仅升 0.19 个百分点；输入降至 64×64 跌至 0.6405，下降约 3.2 个百分点；强增强、Dropout+weight_decay 分别降 0.50 和 0.57 个百分点；全家桶降至 0.6629，降 0.92 个百分点。N1 的重采样版本 0.6763 也低于关闭重采样结果，但两者训练轮数不同，只能作为方向性证据。需要强调，消融均只训练 6 轮，绝对精度不能与 30 轮主实验直接横比。

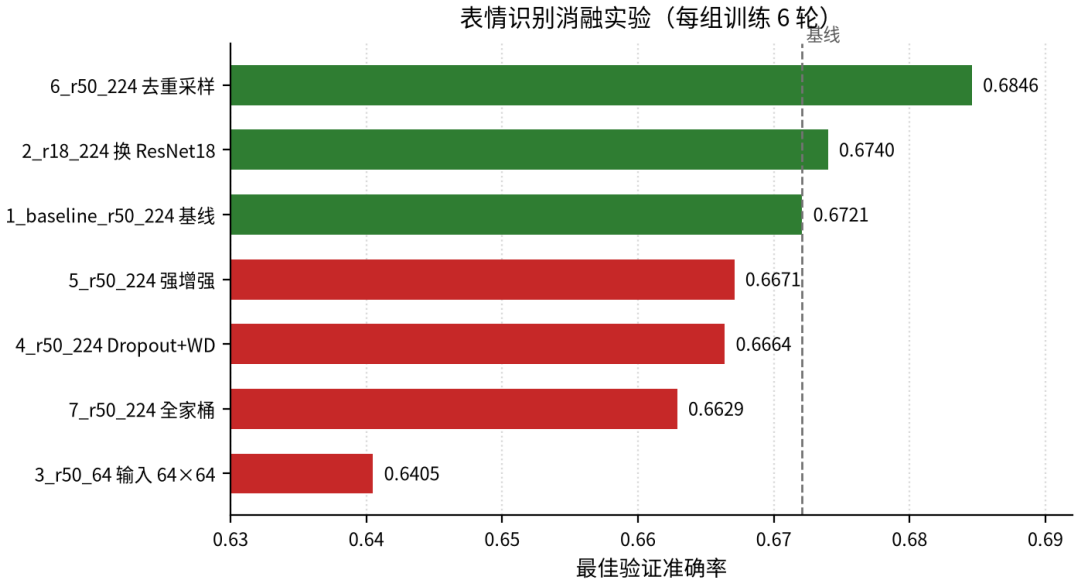


图 2-1　表情识别消融实验：各组最佳验证准确率（每组训练 6 轮）

表 2-2　消融实验结果（每组训练 6 轮）

实验组	改动	最佳验证准确率	Δ/pp
1_baseline_r50_224	基线	0.6721	0.00
2_r18_224	换 ResNet18	0.6740	+0.19
3_r50_64	输入 64×64	0.6405	-3.16
4_r50_224	加 Dropout、weight_decay	0.6664	-0.57
5_r50_224	强增强	0.6671	-0.50
6_r50_224	关闭重采样	0.6846	+1.25
7_r50_224	强增强、Dropout、weight_decay	0.6629	-0.92

2.4.4 线上成绩

两个版本都提交过：N1（15 轮、WeightedRandomSampler、无 TTA）线上 0.678；N2（30 轮、不重采样、水平翻转 TTA）线上 0.679。两者只差 0.001，而验证集上 N2 比 N1 高 0.71 个百分点（0.6834 对 0.6763）。

这个对照说明三件事。其一，验证集上的 0.71 个百分点没有传导到测试集，在本数据规模下很可能只是划分噪声，不足以支撑“N2 的训练策略更优”的结论。其二，按类别倒数重采样虽然纠正了训练集先验，但在 Accuracy 指标下没有带来线上收益，反而牺牲了多数类的判别。其三，更长训练与 TTA 的收益同样有限——三者叠加只换来 0.001。

由此看，本任务的性能上限更多由 48×48 的输入信息量决定，而不是训练策略。这也解释了为什么换 EfficientNet-B0（0.6711）与换采样方式都没有明显改变线上结果。

2.5 分析

2.5.1 224×224 输入

224 不增加信息，但可避免 48×48 在浅层快速下采样后丢失眉眼、嘴角细节，并与 ImageNet 预训练尺度匹配。64×64 损失约 3.2 个百分点，说明空间细节是该任务的关键。

2.5.2 重采样

按类别倒数重采样将训练先验拉向均衡，使决策边界偏向少数类，并重复少数类难样本与噪声；在总体 Accuracy 下会牺牲多数类。本数据不平衡仅 2.25，保留自然先验更合适：验证集上关闭重采样提升 1.25 个百分点，但这一收益在线上没有体现（见 2.4.4），说明它可能被高估。

2.5.3 强增强与组合正则

强增强、Dropout+weight_decay 及全家桶分别下降 0.50、0.57、0.92 个百分点。6 轮短训练下优化预算有限，过强扰动会破坏局部表情线索，多个正则叠加又造成欠拟合。至少在该设置下，继续加正则不是有效方向。

2.5.4 验证波动

验证集约 4241 张，1 个百分点约对应 42 张，数十张样本的归属变化即可造成可见波动。主模型第 20 轮最佳、第 25 轮才早停，说明第 20 轮后连续 5 轮未再提升，验证性能已进入平台期；在 30 轮中取最大值会乐观偏置。EfficientNet 第 6 轮见顶、第 11 轮早停，也说明该模型对训练进程较敏感。故 0.6834 与 0.6711 的 1.23 个百分点差距，在单次划分下不足以证明架构的稳定优势，也会把验证集噪声带入模型选择。

2.6 局限与改进

2.6.1 局限

48×48 源图像信息量有限，ImageNet 权重与表情任务又存在域差异；仅一次 85/15 划分并按最佳轮次选型，缺少 k 折或多种子重复；测试得分未记录，且未分析各类别混淆情况。损失函数也只用了 CrossEntropyLoss。

2.6.2 改进方向

后续可改用表情专用预训练权重，如 AffectNet 等表情数据训练的 EmotiEffLib/HSEmotion 模型；采用 k 折或多 seed 并报告均值、标准差；尝试 Focal Loss、Label Smoothing 或类别加权交叉熵，与不重采样策略结合；也可扩充 TTA 或集成 ResNet18 与 EfficientNet-B0。上述方向均未在本文中实验。

第 3 章　眼底黄斑中央凹定位

本章研究眼底图像中黄斑中央凹的自动定位。该任务形式上可视为目标检测，但最终只需输出一个解剖标志点的坐标，并需处理标志点不可见的情况，因此数据、模型与评价均围绕“点定位”组织。

3.1 任务与数据

输入为单张彩色眼底图，输出为中央凹坐标(X,Y)；不可见时输出(0,0)。训练集 80 张（0001–0080），每张均有 XML 黄斑 bbox 和 CSV 中央凹坐标；测试集 20 张（0081–0100），仅提供图像。评价指标为 RMSE，X 与 Y 分两行计算，以分别反映水平和垂直偏差。测试集不提供真值，只能通过 Kaggle 排行榜获得整体 RMSE，无法逐张核对误差，因此结果以交叉验证为主、榜单为辅。

3.2 关键观察与问题转化

对训练集的核对显示，XML 框中心与 CSV 真值点存在小偏差：ΔX=0.607±1.318px，ΔY=1.316±1.864px，X/Y 方向最大绝对偏差为 4.14px 和 5.0px。若直接把框中心作为坐标，训练集 RMSE 为 1.903px；训练集 80 张全部可见，无(0,0)负样本。图 3-1 以 0049 为例展示标注框与真值点的关系。

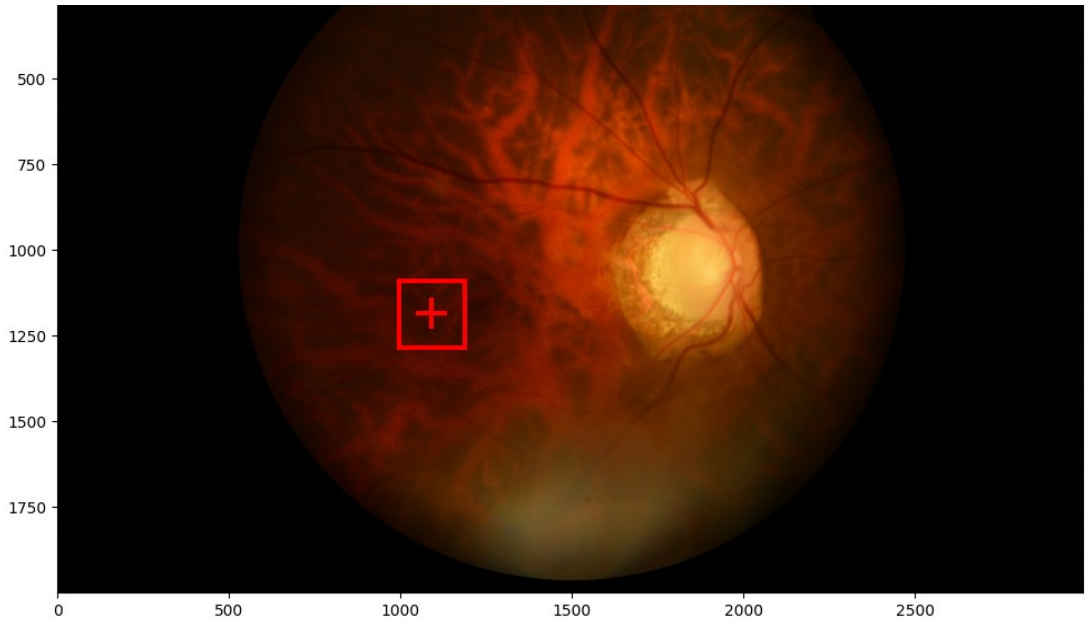


图 3-1　训练样本 0049：XML 标注框与 CSV 真值点（红框为 bbox，十字为中央凹真值）

这说明 bbox 中心与中央凹在像素尺度上接近，可将坐标回归转化为目标检测：先定位黄斑，再取预测框中心。需强调，1.903px 是标注几何一致性的度量，不是检测模型的泛化误差，只表明“框中心→点”的转换误差量级较小；转化能否奏效，取决于模型能否在未见图像上稳定覆盖黄斑。

3.3 方法设计

模型采用 Faster R-CNN（ResNet50-FPN v2），加载 COCO 预训练权重；检测头输出背景与黄斑两类。为降低小数据过拟合，冻结 backbone 的 layer1 与 layer2，输入缩放至 800×800。

增强由 albumentations 同步变换图像与 bbox，包括 Rotate±15、BrightnessContrast 和 ColorJitter。训练采用 5 折 KFold(shuffle=True, random_state=42)，25 个 epoch，batch size=8；AdamW，lr=1e-4, CosineAnnealingLR；梯度裁剪 1.0；按 best val_rmse 保存权重。推理取预测框中心，检测分数低于 tau 时输出(0,0)；提交时 make_submission 传入 tau=0.0，即 20 张图全部按“可见”输出坐标。

3.4 实验设置

主实验即上述 5 折方案，每折 16 张验证图，得到 5 个折内最佳验证 RMSE。同一配置先后训练两次，两次都完整跑了 5 折，配置一致（batch size=8、25 epoch、5 折），差别只来自初始化与训练过程中的随机性，因此可以把两次结果并列比较，用来估计该配置的方差。

3.5 结果

同一配置先后训练两次，结果差别很大，因此分别报告。

表 3-1　第一次运行：五折验证结果

折	fold0	fold1	fold2	fold3	fold4	均值
RMSE/px	14.76	15.89	4.58	17.66	16.90	13.96

表 3-2　第二次运行：五折验证结果

折	fold0	fold1	fold2	fold3	fold4	均值
RMSE/px	14.10	12.45	4.50	22.15	111.81	33.00

第一次运行五折都在 4.58–17.66 px 之间，均值 13.96 px，最好折 4.58 px。第二次运行前四折与第一次接近（4.50–22.15 px），但 fold4 在训练中出现过 899.87 的尖峰，最终停在 111.81 px，把均值推到 33.00 px。两次运行配置相同，差别来自初始化的随机性与小数据下检测器优化的不稳定性。

提交采用第一次运行的 5 个模型集成。20 张测试图的检测置信度在 0.416–0.982 之间：最低是 0086 的 0.416，其次是 0081 的 0.781，其余 18 张都在 0.92 以上。make_submission 传入 tau=0.0，因此没有一张被置为(0,0)，全部按“可见”输出坐标。

需要说明的是，0086 这张的置信度显著偏低。按训练集的经验，低分往往对应大误差，但测试集没有真值，无法确认它是否真的偏了；它同时也没有被阈值拦下，因为阈值设为 0.0。这正是缺少“不可见”负样本带来的后果——分数低不代表判错，而没有标签就没有校准依据。

另附训练集上的误差统计：最大的五张是 0049（69.4 px）、0034（64.9 px）、0072（62.2 px）、0062（58.6 px）、0016（51.4 px），均为框中心误差，不是测试集结果。

3.6 分析

第二次运行的 fold4（111.81 px）是主要异常，训练中曾出现 899.87 px 的 RMSE 尖峰。现有记录只能支持“训练不稳定、回归头崩溃”的描述，不能断言具体机制，也不能说该问题已被梯度裁剪或最佳权重保存修复——最终 fold4 仍然异常。更稳妥的结论是：当前数据规模与配置下，检测器优化存在明显的折间不稳定性，单次训练结果不可靠。

同一配置的两次运行，均值分别为 13.96 px 与 33.00 px，差距超过一倍，说明小数据下折间方差主导汇总结果。33.00 是 5 个折内最佳 val_rmse 的算术平均，并

非合并 80 张验证预测后重算的总体 OOF；每折仅 16 张，等权平均放大 fold4 的影响，也不能给出总体标准误。因此它应理解为各折表现的等权汇总，不宜当作无偏泛化估计。

线上私榜 17.42、终榜 21.11，与验证均值 13.96 分别差 3.5 px 和 7.1 px。测试集只有 20 张，单张误差即可明显改变 RMSE，因此这个差距在合理范围内；但它也说明 13.96 这个验证均值偏乐观——每折只有 16 张，且 best epoch 是在同一验证集上挑出来的，存在选择偏差。

3.7 局限与改进

第一，训练集无(0,0)负样本，模型无法学习不可见类别。当前仅靠检测分数加阈值，提交时 tau=0.0，20 张测试图全部按可见处理，实际没有发挥作用；交叉验证也无不可见样本，阈值缺乏验证集支撑。若测试集存在不可见图，方法会误输出坐标。应补充不可见图或显式可见性标签，并在独立验证集上选 tau。

第二，折间方差过大：同一配置两次运行，五折均值为 13.96 与 33.00，最佳单折 4.58 与最差单折 111.81 相差二十余倍；每折仅 16 张，且 best epoch 在同一验证集上选择，存在选择偏差。应采用重复交叉验证、嵌套验证或固定外部测试集，并报告均值、标准差和逐折结果。

第三，当前仅利用 bbox 中心，框回归未被显式约束到中央凹点。可增加中心偏移回归分支，或引入关键点热图与多任务损失，直接优化坐标误差，并对集成做置信度校准。上述改进尚未实施，本文不声称问题已解决；测试集无真值，结论仍以交叉验证为主。

第 4 章　眼底血管分割

本章研究眼底图像血管分割。血管细长、末梢仅数像素宽且对比度低，难点在于细小血管的连续性与低对比区域召回。本文以 UNet 为骨干，结合 Tversky 损失、五折集成与测试时增强（TTA），并对分辨率、损失、预处理和骨干规模做消融。

4.1 任务与数据

训练集 20 对眼底图像与二值标注，血管取 255、背景取 0；测试集 20 张。评价指标为 Dice 系数，提交文件为 RLE 编码的 CSV。每折验证仅 4 张，单图误差即可引起明显波动，故同时报告五折均值与各折结果。

4.2 方法设计

4.2.1 模型与损失

分割网络采用 segmentation_models_pytorch 的 UNet，编码器 ResNet18，加载 ImageNet 预训练权重，输入 3 通道 RGB，输出单通道概率图。损失函数为 0.3×BCE+0.7×Tversky（α=0.3，β=0.8）。Tversky 损失的分母中 β 乘漏检、α 乘误检，β>α 使漏检受罚更重，符合血管忌断裂的先验；BCE 项提供稳定的逐像素梯度。

4.2.2 预处理

图像与标注统一缩放至 768×768。第二次实验（记 2nd）的主训练数据读取流程没有 CLAHE，其主结果是在无 CLAHE 条件下取得的；第三次实验（记 3rd）加入 CLAHE 后，两次五折均值为 0.7863 与 0.7812，与 2nd 的 0.7863 基本持平，no_clahe 消融亦无增益，故最终方案不采用 CLAHE。

4.2.3 五折训练、全量模型与集成

采用 5 折交叉验证，随机种子设为 42，每折 16 张训练、4 张验证；AdamW，lr=5×10^{-4}，weight_decay=1×10^{-4}，余弦退火，最多 60 个 epoch，早停耐心为 15。另用全部 20 张训练全量模型 100 个 epoch，T_max=100。预测时将五折均值乘以 5/6、全量模型乘以 1/6 后相加，每个模型做原图、水平翻转、垂直翻转三向 TTA 后平均。

4.2.4 后处理与导出

概率图以 0.6 为阈值二值化，删除面积小于 50 像素的连通域，保存 PNG。用官方 segmentation_to_csv.py 生成 RLE，按 sample_submission 的 Id 顺序重排。官方脚本会将 768×768 预测压回 512×512 再编码，验证与提交存在分辨率口径差。

4.3 实验设置

实验分 2nd 与 3rd 两次独立运行，均采用随机种子 42 的 5 折交叉验证，主结果以五折验证 Dice 的均值报告。消融固定 60 个 epoch、关闭早停、不回载 best、Dice 按 0.5 计算，与主训练协议不同，绝对值不可直接比较。

4.4 结果

表 4-1 为两次运行的五折 Dice。2nd 均值 0.7863（0.7888、0.7473、0.8083、0.7954、0.7915）；3rd 重跑均值 0.7812（0.7719、0.7470、0.8048、0.7935、0.7887），提交采用后者。两次均值相差 0.005，但各折之间波动明显（3rd 为 0.7470–0.8048），说明单折分数受数据划分与训练随机性影响很大。

表 4-1　两次独立运行的五折验证 Dice

折次	2nd Dice	3rd Dice（重跑）
第 1 折	0.7888	0.7719
第 2 折	0.7473	0.7470
第 3 折	0.8083	0.8048
第 4 折	0.7954	0.7935
第 5 折	0.7915	0.7887
均值	0.7863	0.7812

图 4-1 展示测试样本的原图、真值及不同配置的预测，图中标注的 Dice 为验证集指标，仅用于配置间相对比较。

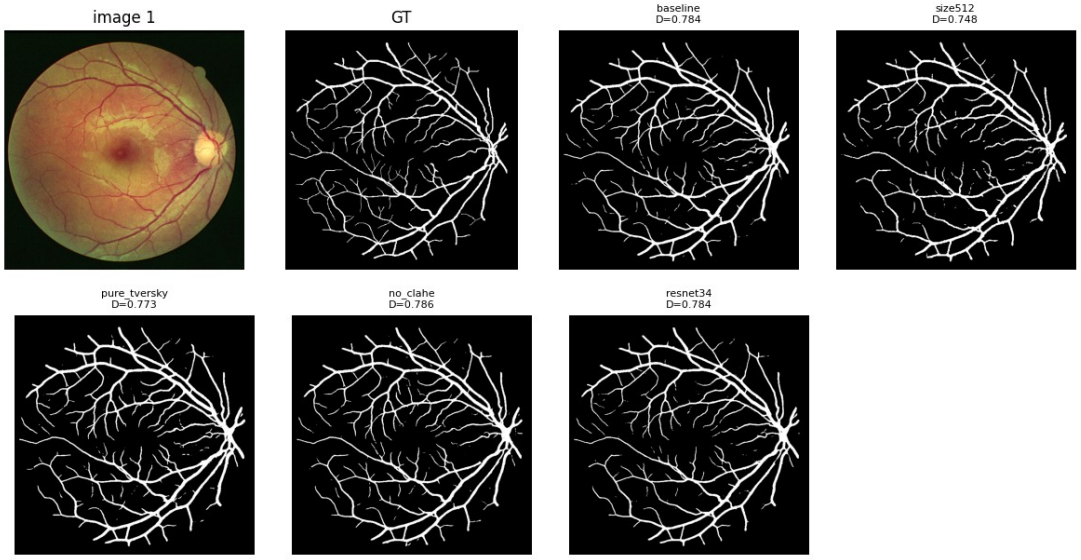


图 4-1　测试样本的分割结果对比（上排自左至右：原图、真值、baseline、size512；下排自左至右：pure_tversky、no_clahe、resnet34；标注为验证 Dice）

表 4-2 为 2nd 消融结果：baseline 为 0.7837；size512 降至 0.7482（−0.036），降分辨率损失最大；pure_tversky 降至 0.7727（−0.011），BCE 不可省；no_clahe 为 0.7865（+0.003）、resnet34 为 0.7842（+0.0005），均在噪声内。

表 4-2　2nd 消融实验结果（60 轮、不早停、不回载 best、阈值 0.5）

配置	Dice	相对 baseline
baseline	0.7837	—
size512	0.7482	−0.036
pure_tversky	0.7727	−0.011
no_clahe	0.7865	+0.003
resnet34	0.7842	+0.0005

导出检查：提交文件按 512×512 口径编码，第 1 行前景 34496 像素（约占 13%）；掩码保存为 PNG，避免有损压缩改变前景像素。提交 Id 为 1–20 连续、缺失值为 0、shape 为(20,2)。线上成绩：私榜 Dice 0.82632，终榜 0.82947。线上高于验证均值（0.7812），可能因为测试集图像质量更均匀、或官方按 512×512 口径计算 RLE，降采样后细血管被裁掉、评分口径与 768 验证不同。

4.5 分析

β>α 的召回偏向。血管像素占比不足一成，正负样本极不平衡。β=0.8 对漏检的权重约为 α=0.3 对误检的 2.7 倍，模型倾向于提高召回，宁可多判背景为血管，也不愿让血管中断，这对保持血管连续性有利。但 pure_tversky 降至 0.7727，提示纯区域损失在训练早期不够稳定，BCE 的逐像素约束不可省。

集成与 TTA。五折模型在不同划分上训练，平均可降低单折模型对特定 4 张验证图的方差，对测试集则近似多模型投票；三向翻转 TTA 把不同朝向的预测拉回同一坐标系平均，降低方向敏感性。本文未报告单折无 TTA 对照，故只将其作用归为方差缩减，不给数值增益。

消融协议的可比性。主训练用早停并回载 best、阈值 0.6，消融固定 60 个 epoch、不回载 best、阈值 0.5，因此 2nd 主结果的 0.7863 与消融 baseline 的 0.7837 之间的 0.0026 差值不能归因于单一改动。表 4-2 的差值仅在消融协议内部有效；每折仅 4 张验证图，0.003 量级差异不足以判定优劣。

CLAHE 无增益。no_clahe 为 0.7865，较 baseline 高 0.003，落在噪声内；2nd 主训练本无 CLAHE，均值 0.7863 与 no_clahe 的 0.7865 几乎一致；3rd 加入 CLAHE 后两次运行为 0.7863 与 0.7812，没有稳定提升。20 张图下，局部增强可能同时放大背景噪声与血管边缘光晕，其收益被抵消。

分辨率的影响最大。512 输入使 Dice 下降 0.036，末梢血管在降采样中被抹去；ResNet34 仅提高 0.0005，说明 20 张图下增大骨干无明显收益。

4.6 踩过的坑

余弦周期与轮数不一致。2nd 的全量模型设 T_max=80，却执行 100 个 epoch，余弦周期短于总轮数，最后 20 轮不再处于原定退火区间，训练节奏与设定不符；3rd 将 T_max 改为 100，使退火覆盖全程。五折模型为 60 轮，不受影响。

PNG 与 JPG。若存 JPG，有损压缩会在血管边缘引入中间灰度，改变前景像素，使原本只有{0,255}的图不再纯净。本文未做 JPG 对照，此项仅作为潜在风险记录，正式流程统一使用 PNG。

4.7 局限与改进

局限主要有三：数据仅 20 张，每折验证只有 4 张，Dice 波动范围大；线上（0.826 / 0.829）高于验证（0.781），差约 0.045，现有记录无法归因；消融与主训练协议不一致，集成、TTA、阈值与连通域的影响也缺少同协议下的定量拆解，贡献只能定性；官方 RLE 按 512×512 口径编码，而训练预测在 768×768，降采样会损失末梢血管，验证与提交存在口径差。

改进方向包括：统一训练与消融协议，补做集成、TTA、阈值与连通域的因子实验；在 512×512 解码口径上直接评估，或多尺度预测后按官方口径融合；针对细血管引入连通性约束；增加折数或重复实验，报告均值与方差。CLAHE 在 20 张数据上无增益，不应优先投入。

结语

四项任务的横向比较

维度	植物分类	表情识别	黄斑定位	血管分割
数据瓶颈	样本极少（500 张）	分辨率低（48×48）	样本极少（80 张）	标注极少（20 对）
最关键的一步	模型容量与正则的取舍	输入分辨率	问题转化（框中心）	损失函数与阈值
提升最大的做法	换 EfficientNet-B0（+0.015）	224 输入、去重采样（+1.25pp）	bbox 中心代替直接回归（1.90 px）	Tversky 加重漏检惩罚
最大教训	增强与正则整体有效，但单折结论会翻转	重采样在 Accuracy 下有害	同配置两次运行差 19 px	验证协议不同不能横比

可复用的经验

1. **先修数据管线，再调模型**。四项任务里，收益最大的改动往往不在网络结构上：黄斑定位把回归问题改写成“检测框取中心”，训练集 RMSE 降到 1.90 px；血管分割的提交必须用 PNG 保存二值 mask、再用官方脚本转 RLE 并重排 Id，否则格式问题会直接吞掉全部精度。

2. **验证协议的差异比结果差异更大**。 血管分割的消融实验固定 60 轮、不早停、不回载最佳权重、Dice 按 0.5 计算，而主训练按 best-val 保存、阈值取 0.6，两者不能直接横比。同样，黄斑定位的三折对照用 bs=4、10 轮，主实验用 bs=8、25 轮。写报告时必须把协议差异交代清楚，否则数字会误导。
3. **小数据下方差是第一位的**。 黄斑定位五折为 4.50、12.45、14.10、22.15、111.81，单折最好与最差相差二十余倍；植物分类五折标准差 0.032；表情识别验证集在不同轮次间来回摆动 1–2 个百分点。单次划分的结论不可靠，这也是四项任务都采用 k 折或多种子平均的原因。
4. **先对齐预算，再比较模型**。 植物分类的消融里 EfficientNet-B0 是 −0.0101，五折均值却是 +0.0154。查配置才发现：消融只换 backbone，沿用 baseline 的 30 轮、patience=5；主流程的 EfficientNet-B0 用 40 轮、patience=10。同一折上两者差 0.0200，完全来自训练轮数。跨实验比较之前，先确认预算是否一致。
5. **记录每一次运行**。 本报告写作过程中最大的时间成本不是跑实验，而是核对数字：同一任务存在多个 notebook 版本，早期版本与最终版本的结果不同，若不记录配置与输出，很容易把不同实验的数字混在一起。

不足

· 四项任务均只做了单机单卡训练，未尝试半监督、伪标签或更大规模的外部数据；
· 表情识别未使用表情专用预训练权重，也未做模型集成；
· 黄斑定位的训练集没有负样本，“不可见”只能靠置信度阈值判断，缺少可验证的准则；
· 血管分割的阈值 0.6 只在验证集上调过，未在测试分布上复核；
· 测试集无标签，本报告无法给出可信的泛化误差，只能以验证集指标与预测分布作为参考。

体会

四项任务做完，最直接的收获不是某个模型或某个技巧，而是判断顺序：拿到一个问题，先看数据规模和标注质量，再看评价指标与验证协议，最后才决定改模型、改数据管线还是改问题的表述方式。多数时候，后两者比换网络有效。另一件事是诚实：把跑出来的数字原样写下来，哪怕它不如预期，也比一个漂亮但对不上的数字有用——后者在复查时一站就穿。

附录　复现信息

- 框架：PyTorch + torchvision；分割任务另用 `segmentation_models_pytorch`，检测任务用 torchvision 的 Faster R-CNN；增强用 albumentations
- 环境：Kaggle Notebook，GPU 为 NVIDIA Tesla T4
- 随机种子：数据划分与模型初始化在可设置的环节固定为 42
- 代码仓库：<https://github.com/KathrynCG/ML-CourseDesign>（含四个任务的 notebook 与各任务原始记录）
- 竞赛主页：<https://www.kaggle.com/neucx11/competitions>
- 数据：由课程在 Kaggle 竞赛页提供，未使用外部数据