机器学习

课程设计报告

四项 Kaggle 任务的建模与优化

姓名　高子恒

学号　20245613

班级　人工智能 2402

东北大学　计算机科学与工程学院

2026 年 11 月

摘要

本报告汇总课程设计中的四项任务，均以 Kaggle 竞赛形式给出：小样本植物图像分类、人脸表情识别、眼底黄斑中央凹定位与眼底血管分割。四者分别对应小样本分类、类别不均衡的细粒度分类、目标检测与坐标回归、医学图像二值分割四类典型问题。

四项任务共用一条技术主线：以 ImageNet 预训练骨干为基础做迁移学习，配合与任务匹配的数据增强，按验证集指标保存最佳轮次，最后用多折集成与测试时增强（TTA）压低方差。在此之上，各任务的处理重点不同：植物分类考察小样本下正则化与模型容量的取舍；表情识别考察输入分辨率与类别不均衡的处理；黄斑定位把坐标回归转化为“检测框中心”的检测问题；血管分割的关键在于损失函数对漏检的惩罚、阈值选取与提交格式。

主要结果（验证集指标＋线上提交成绩）：

· 植物图像分类：五折 Macro-F1，ResNet18 为 0.8998，EfficientNet-B0 为 0.9152；线上提交两次，0.9074 与 0.9047；

· 人脸表情识别：最佳验证准确率 0.6834（第 20 轮），线上 0.679；另一版本（15 轮、重采样、无 TTA）线上 0.678，两版只差 0.001；

· 黄斑中央凹定位：五折验证 RMSE 各折为 14.76、15.89、4.58、17.66、16.90，均值 13.96；线上公开榜 21.11、最终榜 17.42。另有一次独立训练在 fold4 崩溃（OOF 33.00），两相对照说明小数据下的不稳定性；

· 眼底血管分割：五折验证 Dice 均值 0.7863（第二次独立运行为 0.7812）；线上公开榜 0.82947、最终榜 0.82632。

报告中的全部数值均取自 notebook 的实际运行输出，未做修饰。四项任务也留下了若干值得记录的判断，例如植物分类中增强与正则整体是正贡献（移除绝大多数模块都掉分）、表情识别中输入分辨率的影响大于更换骨干网络、黄斑定位同一配置两次运行的五折均值可以从 13.96 px 变成 33.00 px，这些结论连同证据一并写在对应章节中。

关键词：迁移学习；小样本分类；类别不均衡；目标检测；医学图像分割；交叉验证集成

引言

四项任务一览

任务	类型	数据（训练/测试）	验证结果	线上成绩
植物分类	小样本	500 / 378	Macro-F1 0.9152（五折）	0.9074、0.9047
表情识别	细粒度	28275 / 7065	Accuracy 0.6834	0.679
黄斑定位	检测＋回归	80 / 20	RMSE 13.96（五折均值）	公开 21.11 / 最终 17.42
血管分割	语义分割	20 对 / 20	Dice 0.7863 / 0.7812	公开 0.82947 / 最终 0.82632

四项任务的测试集均不提供标签。各章报告的是该任务**最终提交、线上成绩最好**的那次运行；验证指标取自对应 notebook 的实际输出，线上成绩取自 Kaggle 排行榜，公开榜与最终榜分别列出。若同一配置另有独立运行且结果差异明显，一并列出，用于说明小数据下的方差。

共同的技术路线

四项任务的数据规模都不足以从零训练深度网络，因此统一采用迁移学习：

1. **骨干**：以 ImageNet 预训练的 ResNet18 为主，另在对照中尝试 EfficientNet-B0、ResNet34、ResNet50、Faster R-CNN（ResNet50-FPN）与 UNet（ResNet18 编码器）；
2. **输入**：分类任务统一放大到 224×224，分割任务 768×768，检测任务 800×800，均使用 ImageNet 均值方差归一化；
3. **增强**：分类任务用翻转、旋转、颜色扰动与随机擦除，检测与分割任务用图像和标注同步变换；

4. **训练**：AdamW 为主，余弦退火或阶段式学习率，按验证集指标保存最佳轮次，配合早停与梯度裁剪；
5. **推理**：多折模型集成，叠加翻转类 TTA，最后按竞赛模板重排提交文件。

报告组织

四个任务各自独立成章，依次为第 1 至第 4 章，每章结构一致：任务与数据、方法设计、实验设置、结果、分析、局限与改进。开头的引言说明四项任务的共同背景与技术路线，结语只做简短收束，不复述各章结论。附录给出复现信息与代码仓库地址。

第 1 章　小样本植物图像分类

1.1 任务与数据

本任务为 5 类植物幼苗图像的单标签分类，类别为 Black-grass、Common wheat、Loose Silky-bent、Scentless Mayweed 与 Sugar beet，评价指标为 Macro-F1。训练集 500 张，5 类各 100 张，完全均衡；测试集 378 张，不提供标签。图像统一缩放至 224×224，背景多为土壤，光照与拍摄距离差异明显。每类仅 100 张且禁用外部数据，模型容易依赖背景而非叶片形态；Black-grass 与 Loose Silky-bent 苗期均为细长窄叶，类间边界模糊，因此方法需以迁移学习为主。

1.2 方法设计

1.2.1 整体框架

训练图经随机增强送入 ImageNet 预训练骨干，再由 Dropout 与线性层输出 5 类 logits；两阶段训练后，集成 5 折×2 骨干共 10 个模型，推理时再做水平翻转 TTA。

1.2.2 模型结构与训练策略

ResNet18 参数量 11.18M，特征维度 512；EfficientNet-B0 参数量 4.01M，特征维度 1280。两者均加载 ImageNet 权重，分类头改为 Dropout(0.5)加 Linear(→5)。第

一阶段冻结骨干，仅训练分类头 8 轮，学习率 1e-3；第二阶段解冻全部参数，微调 30 轮，学习率 1e-4，采用 CosineAnnealing，patience=5。前者避免新初始化的分类头破坏预训练特征，后者使骨干适配植物域。优化器为 AdamW，batch size 为 16，weight_decay 为 1e-4，LabelSmoothing 为 0.1。

1.2.3 数据增强

表 1-1　训练阶段的数据增强

增强方式	参数	设计动机
RandomResizedCrop	scale=(0.7,1.0)	模拟尺度变化
RandomHorizontalFlip	p=0.5	利用左右对称性
RandomRotation	15°	覆盖拍摄角度变化
ColorJitter	亮度、对比度、饱和度均为 0.3	适应光照差异
RandomErasing	p=0.25	模拟局部遮挡

1.2.4 集成与 TTA

按 StratifiedKFold 划分 5 折，seed=42，每折训练两个骨干，共 10 个模型。推理时对原图与水平翻转图的 softmax 概率取平均，再对 10 个模型等权平均后取 argmax。概率平均比投票更平滑，可削弱单模型的过置信错误。

1.3 实验设置

表 1-2　训练与交叉验证设置

项目	设置
交叉验证	StratifiedKFold，5 折，seed=42
每折训练/验证	400 张/100 张
batch size	16
优化器	AdamW，weight_decay=1e-4
阶段一	冻结骨干，8 轮，lr=1e-3
阶段二	全参数，30 轮，lr=1e-4，CosineAnnealing，patience=5
集成	5 折×2 骨干=10 模型，水平翻转 TTA

消融固定 Fold 0 与 seed=42，共 13 项配置，每次只关闭或替换一个模块，baseline 为 0.9199。超参数搜索在第二个 notebook 中完成，覆盖微调学习率、Dropout 与 LabelSmoothing 三组，主配置取 lr=1e-4、Dropout=0.5、LabelSmoothing=0.1。每折在 100 张验证样本上计算 Macro-F1，报告 5 折均值、标准差及最好/最差折。测试集无标签，只能报告预测分布，不能计算 F1，也不能用于模型选择。

1.4 结果

1.4.1 两模型五折对比

表 1-3　ResNet18 与 EfficientNet-B0 的五折结果（Macro-F1）

模型	参数量	5 折均值	标准差	最好折	最差折
ResNet18	11.18M	0.8998	0.0316	0.9300	0.8455
EfficientNet-B0	4.01M	0.9152	0.0381	0.9599	0.8460

EfficientNet-B0 的均值高 0.0154，最好折高 0.0299；最差折 0.8460 与 0.8455 几乎相同。但它的标准差 0.0381 高于 0.0316，极差 0.1139 也大于 0.0845——上限更高，波动也更大。图 1-1 中 ResNet18 在第 10 轮前后进入平台期，EfficientNet-B0 到第 16 轮附近才见顶。

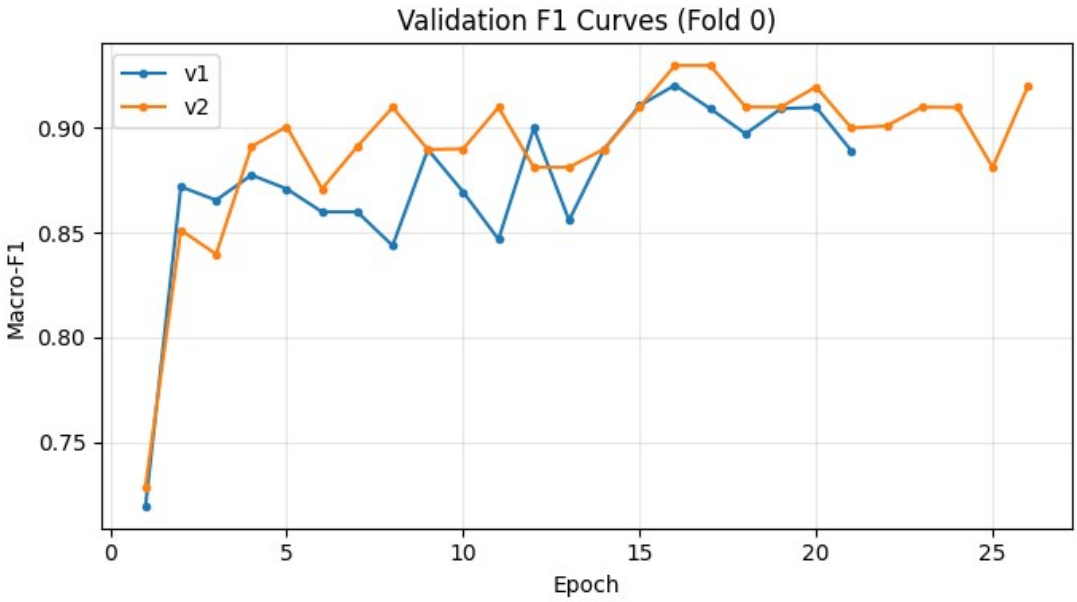


图 1-1　两模型在 Fold 0 上的验证 Macro-F1 曲线

图 1-2 为 ResNet18 在 Fold 0 的混淆矩阵，Macro-F1 为 0.9204，100 张验证图里 8 张错分。

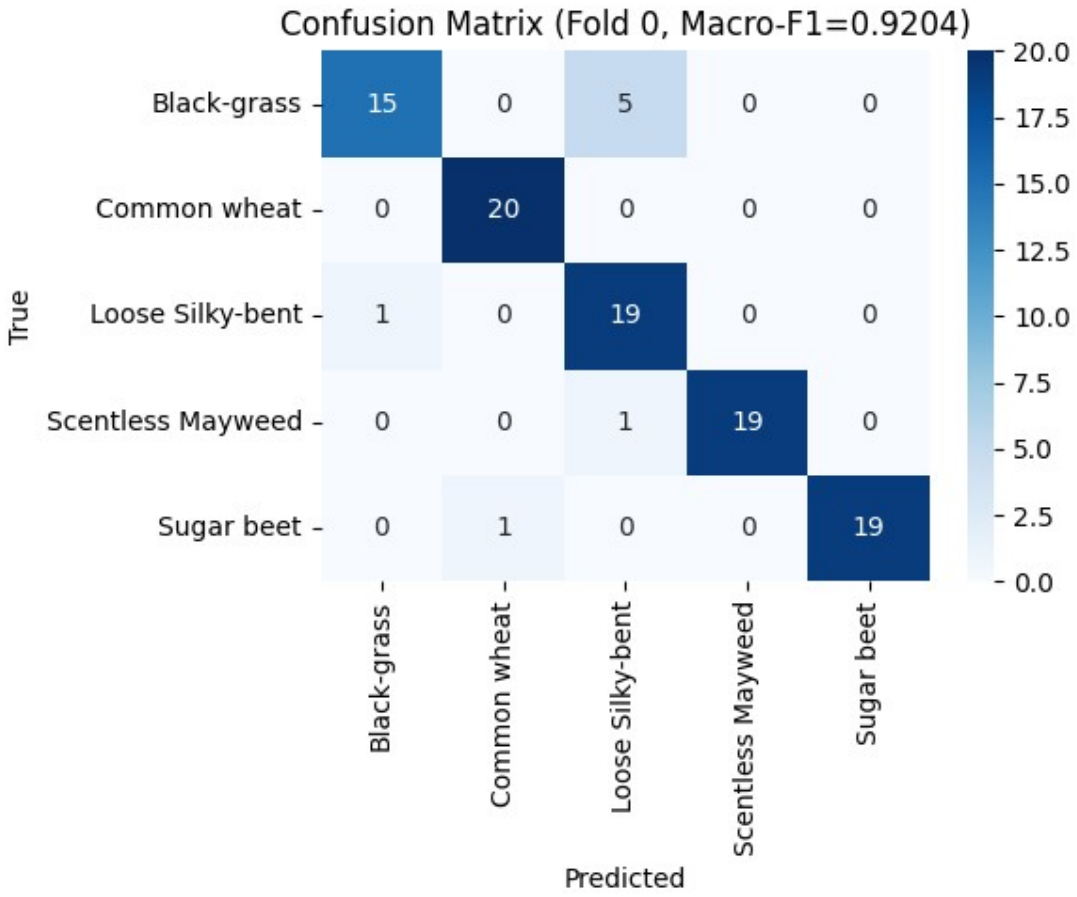


图 1-2　Fold 0 混淆矩阵（ResNet18）

1.4.2 集成与 TTA

10 个模型集成加水平翻转 TTA 后，测试集的预测分布见表 1-4。训练集五类完全均衡，各 100 张；预测分布却明显偏斜，Loose Silky-bent 104 张，Common wheat 只有 37 张，相差 67 张。测试集无标签，这个分布只能说明模型的预测倾向，不能据此计算 F1。

表 1-4　10 模型集成加 TTA 的测试集预测分布

类别	测试集预测数
Loose Silky-bent	104
Scentless Mayweed	91
Sugar beet	82
Black-grass	64
Common wheat	37

1.4.3 消融实验

消融固定 Fold 0，每次只移除或替换一个模块，baseline 为 0.9199，结果见表 1-5 与图 1-3。除 no_erasing 与 baseline 持平（+0.0008，在噪声内）外，其余 11 项全部低于 baseline。

表 1-5　消融实验结果（Fold 0，baseline 0.9199）

配置	Macro-F1	Δ vs baseline
no_erasing	0.9207	+0.0008
baseline	0.9199	0
no_freeze	0.9107	−0.0092
no_dropout	0.9098	−0.0101
efficientnet_b0	0.9098	−0.0101
no_crop	0.9009	−0.0190
no_cosine	0.8999	−0.0200
with_mixup	0.8999	−0.0200
no_label_smoothing	0.8999	−0.0200
no_flip	0.8970	−0.0229
no_colorjitter	0.8897	−0.0302
no_weight_decay	0.8897	−0.0302
no_rotation	0.8789	−0.0410

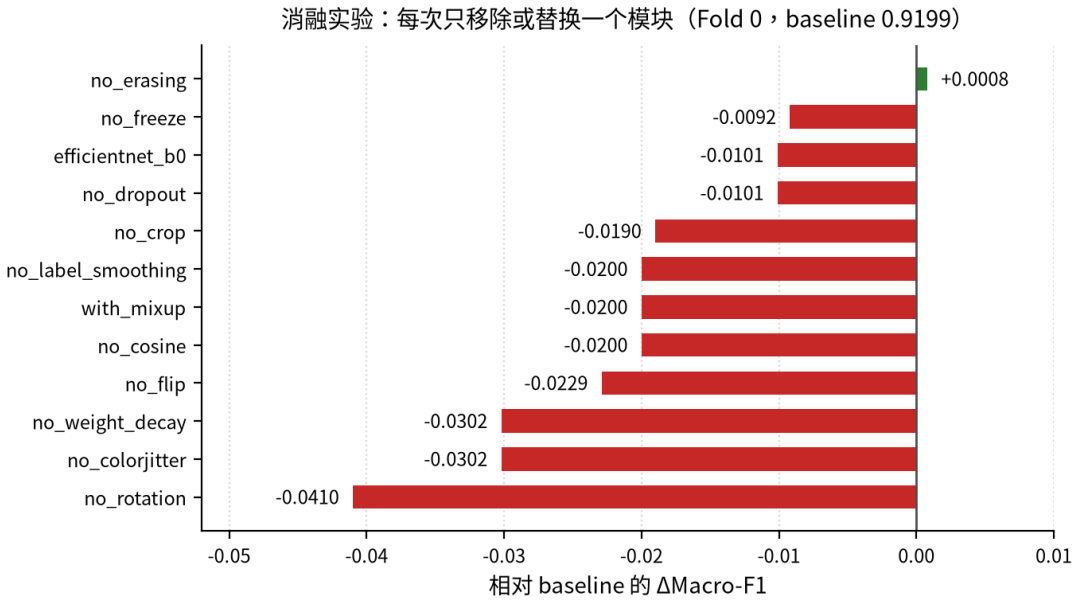


图 1-3　消融实验：各模块相对基线的 ΔMacro-F1

1.4.4 线上成绩

Kaggle 提交两次：第一次（task1）公开榜 0.9074，第二次（task1-2nd）0.9047。两次都低于验证集最优的 0.9152，差距在 0.01 上下，与五折标准差

（0.0316–0.0381）同量级。测试集 378 张，验证每折仅 100 张，两者分布不完全一致，因此线上低于验证属正常范围，不能据此断定过拟合。

1.5 分析

1.5.1 EfficientNet-B0 更优的原因

EfficientNet-B0 在五折均值上领先 0.0154。可能的原因有三：MBConv 的深度可分离卷积与 SE 注意力对细粒度纹理更敏感；4.01M 参数仅为 ResNet18 的 36%，在 500 张样本下容量更可控；复合缩放让深度、宽度与分辨率更平衡。但它的标准差 0.0381 高于 0.0316，均值差小于一个标准差，只能称其在本数据划分下平均更好，不能断言显著占优。

值得注意的是，单折消融里 efficientnet_b0 为 0.9098（−0.0101），与五折结论方向相反。查配置可知，两者不是同一个实验：消融只替换了 backbone，其余沿用 baseline 的 epochs_finetune=30、patience=5；而主流程的 EfficientNet-B0 用的是 40 轮、patience=10。同一折上，主流程的 EfficientNet-B0 为 0.9298，消融版本为 0.9098，0.0200 的差距完全来自训练轮数，与模型结构无关。

逐折看，主流程中 EfficientNet-B0 在五折上都不低于 ResNet18（Fold 0 +0.0094、Fold 1 +0.0299、Fold 2 +0.0005、Fold 3 +0.0272、Fold 4 +0.0096），方向一致。因此模型选择以五折完整评估为准；消融里的 efficientnet_b0 只用于“同折、同预算下换 backbone”的对照，不用于跨模型结论。

1.5.2 增强与正则整体有效

除 no_erasing 外，移除任何一个模块都使 Fold 0 的分数下降：影响最大的是旋转（no_rotation，−0.0410），其次是颜色扰动与权重衰减（各 −0.0302），再次是翻转（−0.0229）、余弦退火与标签平滑（各 −0.0200）。这与“小样本应当加强正则”的直觉一致：数据只有 500 张，增强扩大了有效样本量，正则抑制了过拟合。

有两处需要谨慎解读。其一，no_erasing 为 +0.0008，与 baseline 相差不到千分之一，属噪声；RandomErasing 遮挡 25% 的叶片区域，可能同时抹掉了判别性纹

理，作用方向不稳定。其二，消融只跑 Fold 0、每个配置一次，0.01 量级以下的差异不能当作定论。

1.5.3 小样本下的方差问题

两模型五折标准差为 0.0316 与 0.0381，极差为 0.0845 与 0.1139，对划分敏感。每折验证只有 100 张，单张样本的归属变化即可改变 Macro-F1 约 0.01。0.0154 的均值差小于标准差，不宜做显著性断言；线上两次提交相差 0.0027，也在这个量级内。10 个模型集成加 TTA 在预测层面平均多个输出，有助于降低方差，因此最终提交采用集成而非单折最优模型。

1.5.4 类间混淆集中在两种禾草

图 1-2 的 8 例错分中，6 例发生在 Black-grass 与 Loose Silky-bent 之间：5 例 Black-grass 被判成 Loose Silky-bent，1 例反向。两者苗期都是细长窄叶，缩放后纹理接近，叶宽与颜色差异被削弱。其余两例分别是 Scentless Mayweed 判成 Loose Silky-bent、Sugar beet 判成 Common wheat，各 1 例。

这一分布与测试集预测偏斜方向一致：Loose Silky-bent 被多判（104 张），Common wheat 被少判（37 张）。若测试集类别均衡，模型对 Common wheat 的召回会偏低。后续应针对这一对相似类引入度量学习或二阶段分类器，而不是继续整体加强正则。

1.6 局限与改进

局限有五：测试集无标签，线上与验证之间存在约 0.01 的差距，无法进一步归因；消融仅 Fold 0 且未重复，无置信区间；超参搜索只覆盖三个维度；两阶段轮数与 patience 固定，未与正则强度联合调优；集成加 TTA 的推理开销约为单模型 20 倍。

改进方向：采用 5×5 重复交叉验证，对关键配置使用 3 个随机种子重复；用嵌套交叉验证联合选择正则强度与早停轮数；按类报告 F1 与混淆矩阵，对 Loose Silky-bent 与 Black-grass 引入度量学习或二阶段分类器；在参数量受控下尝试更强预训练权重，并用类先验校正缓解分布偏移。

第 2 章　人脸表情识别

人脸表情识别是细粒度图像分类任务。本章介绍六类表情识别的数据、迁移学习方案与实验结果，并分析影响验证性能的主要因素。

2.1 任务与数据

2.1.1 任务定义

输入一张人脸图像，输出 Angry、Fear、Happy、Sad、Surprise、Neutral 六类之一，以 Accuracy 评价。测试集无公开标签，提交须按模板 ID 排序，故模型选择仅依据验证集。

2.1.2 数据与类别分布

训练集 28275 张，均为 48×48 灰度图（L 模式）；测试集 7065 张，与提交模板 ID 完全对应，缺失 0。类别分布见表 2-1，Happy 最多、Surprise 最少，最大/最小为 2.25，存在中度不平衡。

表 2-1　训练集类别分布

类别	样本数
Angry	3963
Fear	4097
Happy	7192
Sad	4862
Surprise	3202
Neutral	4959
合计	28275

2.2 方法设计

2.2.1 模型与预处理

以 ImageNet 预训练 ResNet18 为主干，最后一层全连接改为 6 类。ResNet18 由残差块构成，参数量适中，适合在有限数据上微调。图像由 L 模式转 RGB，缩放至 224×224 并按 ImageNet 均值、标准差归一化。训练增强为 RandomHorizontalFlip、RandomRotation(10)、ColorJitter(0.2,0.2)；验证和测试仅做确定性缩放与归一化。

2.2.2 划分与训练策略

按 85%/15%分层划分，seed=42，训练约 24034 张、验证约 4241 张；分层保持各类别比例，降低验证集构成偏斜。损失为 CrossEntropyLoss，优化器 AdamW，lr=1e-4、weight_decay=1e-4，CosineAnnealingLR 的 T_max=30。最多训练 30 轮，batch size=32，shuffle=True 且不重采样；以验证准确率监控，patience=5，保存最佳权重并于早停后回滚。

2.2.3 TTA

对原图和水平翻转图各前向一次，对两组 logits 取平均后 argmax；不是对 softmax 概率取平均。TTA 仅用于生成提交。

2.3 实验设置

主实验 N2 使用上述 30 轮配置。N1 作为训练策略参照：训练 15 轮、使用 WeightedRandomSampler、无 TTA。对照模型 EfficientNet-B0 采用相同数据划分与训练框架。消融共 7 组，每组 6 轮并固定同一划分，以 ResNet50、224×224、基础增强为基线，分别改变主干、输入尺寸、采样或正则；6 轮结果只作横向筛选。所有报告值均为验证集最佳 Accuracy，测试标签未参与调参。

2.4 实验结果

2.4.1 主模型

N2 最佳验证准确率 0.6834，出现在第 20 轮，第 25 轮早停；N1 最佳为 0.6763。N2 较 N1 高 0.71 个百分点，但 N1 仅训练 15 轮且使用重采样，差异不能视为单变量收益。N2 经 TTA 的提交预测为 Angry 759、Fear 820、Happy 1781、Sad 1375、Surprise 803、Neutral 1527，六类均有输出，合计 7065 条，未发生类别坍缩。

2.4.2 对照模型

EfficientNet-B0 最佳验证 0.6711，第 6 轮见顶、第 11 轮早停，比 ResNet18 低 1.23 个百分点，差距有限，尚不足以判定主干优劣。

2.4.3 消融实验

表 2-2 和图 2-1 给出 7 组结果。关闭重采样后，最佳验证准确率由 0.6721 升至 0.6846，提升 1.25 个百分点，为最大正向改动；换 ResNet18 仅升 0.19 个百分点；输入降至 64×64 跌至 0.6405，下降约 3.2 个百分点；强增强、Dropout+weight_decay 分别降 0.50 和 0.57 个百分点；全家桶降至 0.6629，降 0.92 个百分点。N1 的重采样版本 0.6763 也低于关闭重采样结果，但两者训练轮数不同，只能作为方向性证据。需要强调，消融均只训练 6 轮，绝对精度不能与 30 轮主实验直接横比。

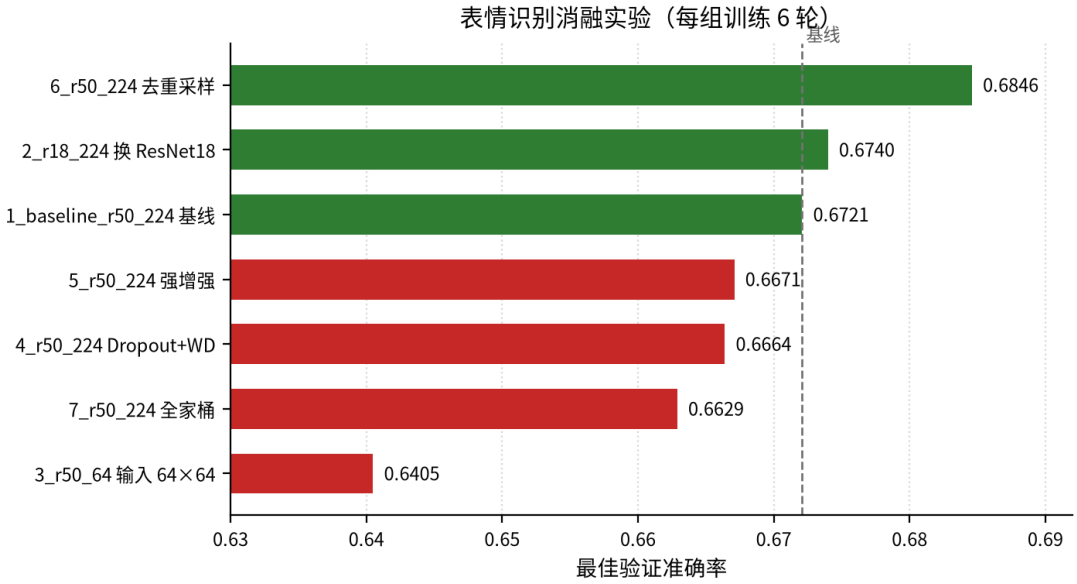


图 2-1　表情识别消融实验：各组最佳验证准确率（每组训练 6 轮）

表 2-2　消融实验结果（每组训练 6 轮）

实验组	改动	最佳验证准确率	Δ/pp
1_baseline_r50_224	基线	0.6721	0.00
2_r18_224	换 ResNet18	0.6740	+0.19
3_r50_64	输入 64×64	0.6405	-3.16
4_r50_224	加 Dropout、weight_decay	0.6664	-0.57
5_r50_224	强增强	0.6671	-0.50
6_r50_224	关闭重采样	0.6846	+1.25
7_r50_224	强增强、Dropout、weight_decay	0.6629	-0.92

2.4.4 线上成绩

两个版本都提交过：N1（15 轮、WeightedRandomSampler、无 TTA）线上 0.678；N2（30 轮、不重采样、水平翻转 TTA）线上 0.679。两者只差 0.001，而验证集上 N2 比 N1 高 0.71 个百分点（0.6834 对 0.6763）。

这个对照说明三件事。其一，验证集上的 0.71 个百分点没有传导到测试集，在本数据规模下很可能只是划分噪声，不足以支撑“N2 的训练策略更优”的结论。其二，按类别倒数重采样虽然纠正了训练集先验，但在 Accuracy 指标下没有带来线上收益，反而牺牲了多数类的判别。其三，更长训练与 TTA 的收益同样有限——三者叠加只换来 0.001。

由此看，本任务的性能上限更多由 48×48 的输入信息量决定，而不是训练策略。这也解释了为什么换 EfficientNet-B0（0.6711）与换采样方式都没有明显改变线上结果。

2.5 分析

2.5.1 224×224 输入

224 不增加信息，但可避免 48×48 在浅层快速下采样后丢失眉眼、嘴角细节，并与 ImageNet 预训练尺度匹配。64×64 损失约 3.2 个百分点，说明空间细节是该任务的关键。

2.5.2 重采样

按类别倒数重采样将训练先验拉向均衡，使决策边界偏向少数类，并重复少数类难样本与噪声；在总体 Accuracy 下会牺牲多数类。本数据不平衡仅 2.25，保留自然先验更合适：验证集上关闭重采样提升 1.25 个百分点，但这一收益在线上没有体现（见 2.4.4），说明它可能被高估。

2.5.3 强增强与组合正则

强增强、Dropout+weight_decay 及全家桶分别下降 0.50、0.57、0.92 个百分点。6 轮短训练下优化预算有限，过强扰动会破坏局部表情线索，多个正则叠加又造成欠拟合。至少在该设置下，继续加正则不是有效方向。

2.5.4 验证波动

验证集约 4241 张，1 个百分点约对应 42 张，数十张样本的归属变化即可造成可见波动。主模型第 20 轮最佳、第 25 轮才早停，说明第 20 轮后连续 5 轮未再提升，验证性能已进入平台期；在 30 轮中取最大值会乐观偏置。EfficientNet 第 6 轮见顶、第 11 轮早停，也说明该模型对训练进程较敏感。故 0.6834 与 0.6711 的 1.23 个百分点差距，在单次划分下不足以证明架构的稳定优势，也会把验证集噪声带入模型选择。

2.6 局限与改进

2.6.1 局限

48×48 源图像信息量有限，ImageNet 权重与表情任务又存在域差异；仅一次 85/15 划分并按最佳轮次选型，缺少 k 折或多种子重复；测试得分未记录，且未分析各类别混淆情况。损失函数也只用了 CrossEntropyLoss。

2.6.2 改进方向

后续可改用表情专用预训练权重，如 AffectNet 等表情数据训练的 EmotiEffLib/HSEmotion 模型；采用 k 折或多 seed 并报告均值、标准差；尝试 Focal Loss、Label Smoothing 或类别加权交叉熵，与不重采样策略结合；也可扩充 TTA 或集成 ResNet18 与 EfficientNet-B0。上述方向均未在本文中实验。

第 3 章　眼底黄斑中央凹定位

本章研究眼底图像中黄斑中央凹的自动定位。该任务形式上可视为目标检测，但最终只需输出一个解剖标志点的坐标，并需处理标志点不可见的情况，因此数据、模型与评价均围绕“点定位”组织。

3.1 任务与数据

输入为单张彩色眼底图，输出为中央凹坐标(X,Y)；不可见时输出(0,0)。训练集 80 张（0001–0080），每张均有 XML 黄斑 bbox 和 CSV 中央凹坐标；测试集 20 张（0081–0100），仅提供图像。评价指标为 RMSE，X 与 Y 分两行计算，以分别反映水平和垂直偏差。测试集不提供真值，只能通过 Kaggle 排行榜获得整体 RMSE，无法逐张核对误差，因此结果以交叉验证为主、榜单为辅。

3.2 关键观察与问题转化

对训练集的核对显示，XML 框中心与 CSV 真值点存在小偏差：ΔX=0.607±1.318px，ΔY=1.316±1.864px，X/Y 方向最大绝对偏差为 4.14px 和 5.0px。若直接把框中心作为坐标，训练集 RMSE 为 1.903px；训练集 80 张全部可见，无(0,0)负样本。图 3-1 以 0049 为例展示标注框与真值点的关系。

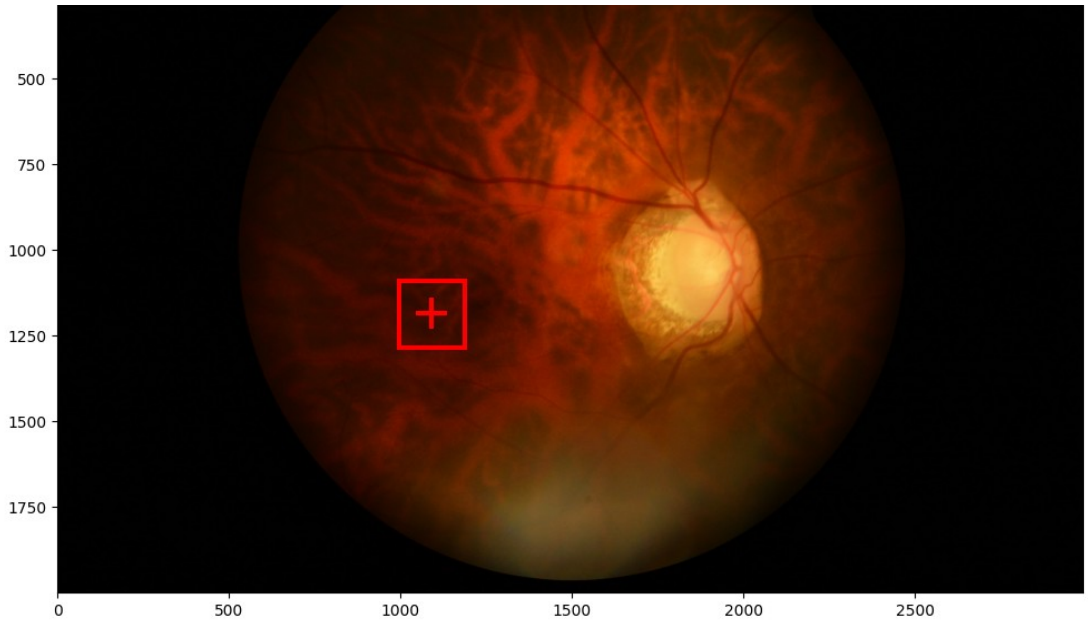


图 3-1　训练样本 0049：XML 标注框与 CSV 真值点（红框为 bbox，十字为中央凹真值）

这说明 bbox 中心与中央凹在像素尺度上接近，可将坐标回归转化为目标检测：先定位黄斑，再取预测框中心。需强调，1.903px 是标注几何一致性的度量，不是检测模型的泛化误差，只表明“框中心→点”的转换误差量级较小；转化能否奏效，取决于模型能否在未见图像上稳定覆盖黄斑。

3.3 方法设计

模型采用 Faster R-CNN（ResNet50-FPN v2），加载 COCO 预训练权重；检测头输出背景与黄斑两类。为降低小数据过拟合，冻结 backbone 的 layer1 与 layer2，输入缩放至 800×800。

增强由 albumentations 同步变换图像与 bbox，包括 Rotate±15、BrightnessContrast 和 ColorJitter。训练采用 5 折 KFold(shuffle=True, random_state=42)，25 个 epoch，batch size=8；AdamW，lr=1e-4, CosineAnnealingLR；梯度裁剪 1.0；按 best val_rmse 保存权重。推理取预测框中心，检测分数低于 tau 时输出(0,0)；提交时 make_submission 传入 tau=0.0，即 20 张图全部按“可见”输出坐标。

3.4 实验设置

主实验即上述 5 折方案，每折 16 张验证图，得到 5 个折内最佳验证 RMSE。同一配置先后训练两次，两次都完整跑了 5 折，配置一致（batch size=8、25 epoch、5 折），差别只来自初始化与训练过程中的随机性，因此可以把两次结果并列比较，用来估计该配置的方差。

3.5 结果

同一配置先后训练两次，结果差别很大，因此分别报告。

表 3-1　两次运行的五折验证 RMSE（px）

运行	fold0	fold1	fold2	fold3	fold4	均值
第一次	14.76	15.89	4.58	17.66	16.90	13.96
第二次	14.10	12.45	4.50	22.15	111.81	33.00

第一次运行五折都在 4.58–17.66 px 之间，均值 13.96 px，最好折 4.58 px。第二次运行前四折与第一次接近（4.50–22.15 px），但 fold4 在训练中出现过 899.87 的尖峰，最终停在 111.81 px，把均值推到 33.00 px。两次运行配置相同，差别来自初始化的随机性与小数据下检测器优化的不稳定性。

提交采用第一次运行的 5 个模型集成。20 张测试图的检测置信度在 0.416–0.982 之间：最低是 0086 的 0.416，其次是 0081 的 0.781，其余 18 张都在 0.92 以上。make_submission 传入 tau=0.0，因此没有一张被置为(0,0)，全部按“可见”输出坐标。

需要说明的是，0086 这张的置信度显著偏低。按训练集的经验，低分往往对应大误差，但测试集没有真值，无法确认它是否真的偏了；它同时也没有被阈值拦下，因为阈值设为 0.0。这正是缺少“不可见”负样本带来的后果——分数低不代表判错，而没有标签就没有校准依据。

另外，训练集 0049 的 bbox 与真值位置一致（ΔX=1.1 px、ΔY=4.8 px），但标注框内及整图都看不到黄斑，判断为标注异常样本；模型在该样本上的误差为 69.4 px，属数据质量问题，不是方法缺陷。

另附训练集上的误差统计：最大的五张是 0049（69.4 px）、0034（64.9 px）、0072（62.2 px）、0062（58.6 px）、0016（51.4 px），均为框中心误差，不是测试集结果。

3.6 分析

第二次运行的 fold4（111.81 px）是主要异常，训练中曾出现 899.87 px 的 RMSE 尖峰。现有记录只能支持“训练不稳定、回归头崩溃”的描述，不能断言具体机制，也不能说该问题已被梯度裁剪或最佳权重保存修复——最终 fold4 仍然异常。更稳妥的结论是：当前数据规模与配置下，检测器优化存在明显的折间不稳定性，单次训练结果不可靠。

同一配置的两次运行，均值分别为 13.96 px 与 33.00 px，差距超过一倍，说明小数据下折间方差主导汇总结果。33.00 是 5 个折内最佳 val_rmse 的算术平均，并

非合并 80 张验证预测后重算的总体 OOF；每折仅 16 张，等权平均放大 fold4 的影响，也不能给出总体标准误。因此它应理解为各折表现的等权汇总，不宜当作无偏泛化估计。

线上公开榜 21.11、最终榜 17.42，与验证均值 13.96 分别差 7.1 px 和 3.5 px。最终榜优于公开榜，说明提交没有对公开榜过拟合。测试集只有 20 张，单张误差即可明显改变 RMSE，因此这个差距在合理范围内；但它也说明 13.96 这个验证均值偏乐观——每折只有 16 张，且 best epoch 是在同一验证集上挑出来的，存在选择偏差。

3.7 局限与改进

第一，训练集无(0,0)负样本，模型无法学习不可见类别。当前仅靠检测分数加阈值，提交时 tau=0.0，20 张测试图全部按可见处理，实际没有发挥作用；交叉验证也无不可见样本，阈值缺乏验证集支撑。若测试集存在不可见图，方法会误输出坐标。应补充不可见图或显式可见性标签，并在独立验证集上选 tau。

第二，折间方差过大：同一配置两次运行，五折均值为 13.96 与 33.00，最佳单折 4.58 与最差单折 111.81 相差二十余倍；每折仅 16 张，且 best epoch 在同一验证集上选择，存在选择偏差。应采用重复交叉验证、嵌套验证或固定外部测试集，并报告均值、标准差和逐折结果。

第三，当前仅利用 bbox 中心，框回归未被显式约束到中央凹点。可增加中心偏移回归分支，或引入关键点热图与多任务损失，直接优化坐标误差，并对集成做置信度校准。上述改进尚未实施，本文不声称问题已解决；测试集无真值，结论仍以交叉验证为主。

第 4 章　眼底血管分割

本章研究眼底图像血管分割。血管细长、末梢仅数像素宽且对比度低，难点在于细小血管的连续性与低对比区域召回。本文以 UNet 为骨干，结合 Tversky 损失、五折集成与测试时增强（TTA），并对分辨率、损失、预处理和骨干规模做消融。

4.1 任务与数据

训练集 20 对眼底图像与二值标注，血管取 255、背景取 0；测试集 20 张。评价指标为 Dice 系数，提交文件为 RLE 编码的 CSV。每折验证仅 4 张，单图误差即可引起明显波动，故同时报告五折均值与各折结果。

4.2 方法设计

4.2.1 模型与损失

分割网络采用 segmentation_models_pytorch 的 UNet，编码器 ResNet18，加载 ImageNet 预训练权重，输入 3 通道 RGB，输出单通道概率图。损失函数为 0.3×BCE+0.7×Tversky（α=0.3，β=0.8）。Tversky 损失的分母中 β 乘漏检、α 乘误检，β>α 使漏检受罚更重，符合血管忌断裂的先验；BCE 项提供稳定的逐像素梯度。

4.2.2 预处理

图像与标注统一缩放至 768×768。第二次实验（记 2nd）的读取流程没有 CLAHE，五折均值 0.7863；第三次实验（记 3rd）在 `read_img` 中加入 CLAHE（clipLimit=2.0、tileGridSize=8×8），五折均值 0.7812。两者相差 0.005，在每折仅 4 张验证图的波动范围内，说明 CLAHE 在该任务上没有稳定增益，但 **3rd 确实使用了 CLAHE，最终提交也来自 3rd**。

4.2.3 五折训练、全量模型与集成

采用 5 折交叉验证，随机种子设为 42，每折 16 张训练、4 张验证；AdamW，lr=5×10^{-4}，weight_decay=1×10^{-4}，余弦退火，最多 60 个 epoch，早停耐心为 15。另用全部 20 张训练全量模型 100 个 epoch。预测时将五折均值乘以 5/6、全量模型乘以 1/6 后相加，每个模型做原图、水平翻转、垂直翻转三向 TTA 后平均。

4.2.4 后处理与导出

概率图以 0.6 为阈值二值化，删除面积小于 50 像素的连通域，保存 PNG。用官方 segmentation_to_csv.py 生成 RLE，按 sample_submission 的 Id 顺序重排。官方脚本会将 768×768 预测压回 512×512 再编码，验证与提交存在分辨率口径差。

4.3 实验设置

实验分 2nd 与 3rd 两次独立运行，均采用随机种子 42 的 5 折交叉验证，主结果以五折验证 Dice 的均值报告。消融固定 60 个 epoch、关闭早停、不回载 best、Dice 按 0.5 计算，与主训练协议不同，绝对值不可直接比较。

4.4 结果

表 4-1 为两次运行的五折 Dice。2nd 均值 0.7863（0.7888、0.7473、0.8083、0.7954、0.7915）；3rd 重跑均值 0.7812（0.7719、0.7470、0.8048、0.7935、0.7887），提交采用后者。两次均值相差 0.005，但各折之间波动明显（3rd 为 0.7470–0.8048），说明单折分数受数据划分与训练随机性影响很大。

表 4-1　两次独立运行的五折验证 Dice

折次	2nd Dice	3rd Dice（重跑）
第 1 折	0.7888	0.7719
第 2 折	0.7473	0.7470
第 3 折	0.8083	0.8048
第 4 折	0.7954	0.7935
第 5 折	0.7915	0.7887
均值	0.7863	0.7812

图 4-1 展示测试样本的原图、真值及不同配置的预测，图中标注的 Dice 为验证集指标，仅用于配置间相对比较。

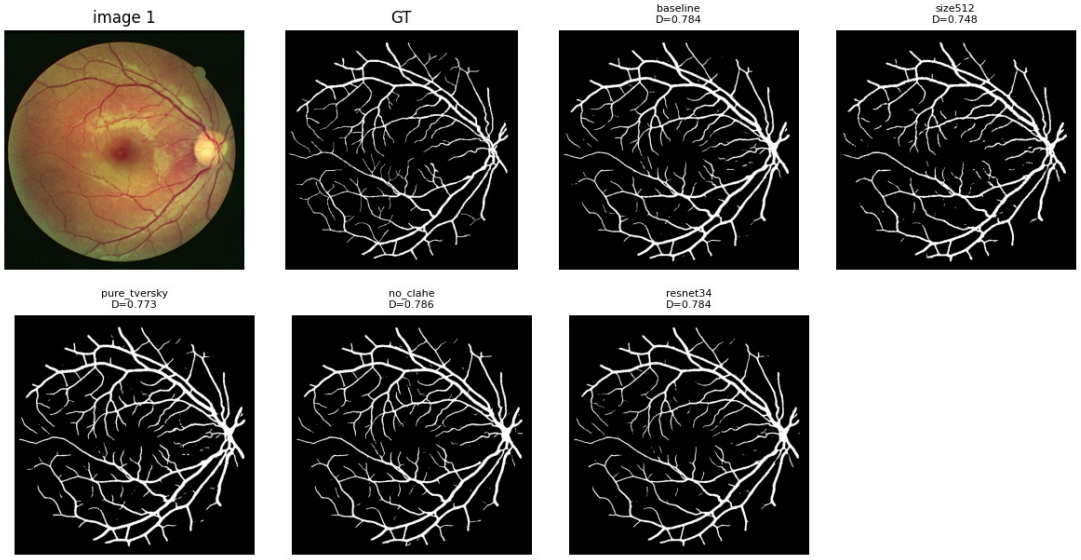


图 4-1　测试样本的分割结果对比（上排自左至右：原图、真值、baseline、size512；下排自左至右：pure_tversky、no_clahe、resnet34；标注为验证 Dice）

表 4-2 为 2nd 消融结果：baseline 为 0.7837；size512 降至 0.7482（−0.036），降分辨率损失最大；pure_tversky 降至 0.7727（−0.011），BCE 不可省；no_clahe 为 0.7865（+0.003）、resnet34 为 0.7842（+0.0005），均在噪声内。

表 4-2　2nd 消融实验结果（60 轮、不早停、不回载 best、阈值 0.5）

配置	Dice	相对 baseline
baseline	0.7837	—
size512	0.7482	−0.036
pure_tversky	0.7727	−0.011
no_clahe	0.7865	+0.003
resnet34	0.7842	+0.0005

导出检查：提交文件按 512×512 口径编码，第 1 行前景 34496 像素（约占 13%）；掩码保存为 PNG，避免有损压缩改变前景像素。提交 Id 为 1–20 连续、缺失值为 0、shape 为(20,2)。线上成绩：公开榜 Dice 0.82947，最终榜 0.82632，最终榜略低。两者都高于验证均值（0.7812），可能因为测试集图像质量更均匀、或官方按 512×512 口径计算 RLE，降采样后细血管被裁掉、评分口径与 768 验证不同。

4.5 分析

β>α 的召回偏向。血管像素占比不足一成，正负样本极不平衡。β=0.8 对漏检的权重约为 α=0.3 对误检的 2.7 倍，模型倾向于提高召回，宁可多判背景为血管，也不愿让血管中断，这对保持血管连续性有利。但 pure_tversky 降至 0.7727，提示纯区域损失在训练早期不够稳定，BCE 的逐像素约束不可省。

集成与 TTA。五折模型在不同划分上训练，平均可降低单折模型对特定 4 张验证图的方差，对测试集则近似多模型投票；三向翻转 TTA 把不同朝向的预测拉回同一坐标系平均，降低方向敏感性。本文未报告单折无 TTA 对照，故只将其作用归为方差缩减，不给数值增益。

消融协议的可比性。主训练用早停并回载 best、阈值 0.6，消融固定 60 个 epoch、不回载 best、阈值 0.5，因此 2nd 主结果的 0.7863 与消融 baseline 的 0.7837 之间的 0.0026 差值不能归因于单一改动。表 4-2 的差值仅在消融协议内部有效；每折仅 4 张验证图，0.003 量级差异不足以判定优劣。

CLAHE 无增益。no_clahe 为 0.7865，较 baseline 高 0.003，落在噪声内；2nd 主训练本无 CLAHE，均值 0.7863 与 no_clahe 的 0.7865 几乎一致；3rd 加入 CLAHE 后为 0.7812，比 2nd 还低 0.005，没有稳定提升，但最终提交仍来自 3rd。20 张图下，局部增强可能同时放大背景噪声与血管边缘光晕，其收益被抵消。

分辨率的影响最大。512 输入使 Dice 下降 0.036，末梢血管在降采样中被抹去；ResNet34 仅提高 0.0005，说明 20 张图下增大骨干无明显收益。

4.6 踩过的坑

余弦周期与轮数不一致。2nd 的全量模型设 T_max=80，却执行 100 个 epoch，余弦周期短于总轮数，最后 20 轮不再处于原定退火区间，训练节奏与设定不符；3rd 仍未修正（依旧 T_max=80、执行 100 轮），因为重跑会牵动全量模型与提交文件，故作为已知缺陷记录。五折模型 60 轮用 T_max=60，不受影响。

PNG 与 JPG。若存 JPG，有损压缩会在血管边缘引入中间灰度，改变前景像素，使原本只有{0,255}的图不再纯净。本文未做 JPG 对照，此项仅作为潜在风险记录，正式流程统一使用 PNG。

4.7 局限与改进

局限主要有三：数据仅 20 张，每折验证只有 4 张，Dice 波动范围大；线上（0.826 / 0.829）高于验证（0.781），差约 0.045，现有记录无法归因；消融与主训练协议不一致，集成、TTA、阈值与连通域的影响也缺少同协议下的定量拆解，贡献只能定性；官方 RLE 按 512×512 口径编码，而训练预测在 768×768，降采样会损失末梢血管，验证与提交存在口径差。

改进方向包括：统一训练与消融协议，补做集成、TTA、阈值与连通域的因子实验；在 512×512 解码口径上直接评估，或多尺度预测后按官方口径融合；针对细血管引入连通性约束；增加折数或重复实验，报告均值与方差。CLAHE 在 20 张数据上无增益，不应优先投入。

结语

四项任务的横向比较

维度	植物分类	表情识别	黄斑定位	血管分割
数据瓶颈	样本极少（500 张）	分辨率低（48×48）	样本极少（80 张）	标注极少（20 对）
最关键的一步	模型容量与正则的取舍	输入分辨率	问题转化（框中心）	损失函数与阈值
提升最大的做法	换 EfficientNet-B0（+0.015）	224 输入、去重采样（+1.25pp）	bbox 中心代替直接回归（1.90 px）	Tversky 加重漏检惩罚
最大教训	增强与正则整体有效，但单折结论会翻转	重采样在 Accuracy 下有害	同配置两次运行差 19 px	验证协议不同不能横比

可复用的经验

1. **先修数据管线，再调模型**。 四项任务里，收益最大的改动往往不在网络结构上：黄斑定位把回归问题改写成“检测框取中心”，训练集 RMSE 降到 1.90 px；血管分割的提交必须用 PNG 保存二值 mask、再用官方脚本转 RLE 并重排 Id，否则格式问题会直接吞掉全部精度。
2. **验证协议的差异比结果差异更大**。 血管分割的消融实验固定 60 轮、不早停、不回载最佳权重、Dice 按 0.5 计算，而主训练按 best-val 保存、阈值取 0.6，两者不能直接横比。同样，黄斑定位的三折对照用 bs=4、10 轮，主实验用 bs=8、25 轮。写报告时必须把协议差异交代清楚，否则数字会误导。
3. **小数据下方差是第一位的**。 黄斑定位五折为 4.50、12.45、14.10、22.15、111.81，单折最好与最差相差二十余倍；植物分类五折标准差 0.032；表情识别验证集在不同轮次间来回摆动 1–2 个百分点。单次划分的结论不可靠，这也是四项任务都采用 k 折或多种子平均的原因。
4. **先对齐预算，再比较模型**。 植物分类的消融里 EfficientNet-B0 是 −0.0101，五折均值却是 +0.0154。查配置才发现：消融只换 backbone，沿用 baseline 的 30 轮、patience=5；主流程的 EfficientNet-B0 用 40 轮、patience=10。同一折上两者差 0.0200，完全来自训练轮数。跨实验比较之前，先确认预算是否一致。
5. **记录每一次运行**。 本报告写作过程中最大的时间成本不是跑实验，而是核对数字：同一任务存在多个 notebook 版本，早期版本与最终版本的结果不同，若不记录配置与输出，很容易把不同实验的数字混在一起。

不足

· 四项任务均只做了单机单卡训练，未尝试半监督、伪标签或更大规模的外部数据；

· 表情识别未使用表情专用预训练权重，也未做模型集成；

· 黄斑定位的训练集没有负样本，“不可见”只能靠置信度阈值判断，缺少可验证的准则；

· 血管分割的阈值 0.6 只在验证集上调过，未在测试分布上复核；

· 测试集无标签，本报告无法给出可信的泛化误差，只能以验证集指标与预测分布作为参考。

体会

四项任务做完，最直接的收获不是某个模型或某个技巧，而是判断顺序：拿到一个问题，先看数据规模和标注质量，再看评价指标与验证协议，最后才决定改模型、改数据管线还是改问题的表述方式。多数时候，后两者比换网络有效。另一件事是诚实：把跑出来的数字原样写下来，哪怕它不如预期，也比一个漂亮但对不上的数字有用——后者在复查时一站就穿。

附录　复现信息

· 框架：PyTorch + torchvision；分割任务另用 `segmentation_models_pytorch`，检测任务用 torchvision 的 Faster R-CNN；增强用 albumentations

· 环境：Kaggle Notebook，GPU 为 NVIDIA Tesla T4

· 随机种子：数据划分与模型初始化在可设置的环节固定为 42

· 代码仓库：<https://github.com/KathrynCG/ML-CourseDesign>（含四个任务的 notebook 与各任务原始记录）

· 竞赛主页：<https://www.kaggle.com/neucx11/competitions>

· 数据：由课程在 Kaggle 竞赛页提供，未使用外部数据